

МИНОБРНАУКИ РОССИИ  
Федеральное государственное бюджетное образовательное учреждение  
высшего образования  
«САРАТОВСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ  
ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ИМЕНИ Н. Г. ЧЕРНЫШЕВСКОГО»

Кафедра дискретной математики и информационных технологий

**РЕАЛИЗАЦИЯ ЗАДАЧИ ТЕМАТИЧЕСКОЙ КЛАССИФИКАЦИИ  
ТЕКСТОВЫХ СООБЩЕНИЙ**

КУРСОВАЯ РАБОТА

студента 1 курса 171 группы  
направления 09.04.01 — Информатика и вычислительная техника  
факультета КНиИТ  
Тарана Евгения Вячеславовича

Научный руководитель  
доцент, к. э. н.

\_\_\_\_\_

Г. Ю. Чернышова

Заведующий кафедрой  
к. ф.-м. н.

\_\_\_\_\_

Л. Б. Тяпаев

Саратов 2026

## СОДЕРЖАНИЕ

|                                                                                           |    |
|-------------------------------------------------------------------------------------------|----|
| ВВЕДЕНИЕ .....                                                                            | 3  |
| 1 Обзор методов классификации текстовых сообщений .....                                   | 5  |
| 1.1 Классические методы классификации текстов .....                                       | 5  |
| 1.2 Архитектура BERT .....                                                                | 6  |
| 1.3 RuBERT: русскоязычная модификация BERT .....                                          | 8  |
| 1.4 Словарные методы анализа тональности .....                                            | 9  |
| 1.5 Группировка целей устойчивого развития в категории .....                              | 10 |
| 2 Классификация текстовых сообщений в соответствии с целями<br>устойчивого развития ..... | 12 |
| 2.1 Применение BERT-модели для тематической классификации .....                           | 12 |
| 2.2 Применение словарных методов для анализа тональности .....                            | 13 |
| 2.3 Апробация для отдельных регионов .....                                                | 14 |
| 2.3.1 Распределение текстов по категориям ЦУР .....                                       | 14 |
| 2.3.2 Тональность по категориям ЦУР .....                                                 | 16 |
| 2.3.3 Межрегиональное сравнение экономической повестки .....                              | 17 |
| СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ .....                                                    | 19 |

## ВВЕДЕНИЕ

В условиях цифровой трансформации общества объёмы текстовых данных, генерируемых в социальных сетях, новостных ресурсах и блогах, растут экспоненциально. Ручной анализ таких данных становится невозможным из-за их масштаба и разнообразия, что делает технологии автоматизированного сбора и анализа текстовой информации критически важными.

Особую актуальность задача автоматического анализа приобретает для русскоязычного контента, где наблюдается дефицит качественных инструментов тематической классификации и оценки тональности, особенно в предметных областях, связанных с целями устойчивого развития (ЦУР). Цели устойчивого развития, принятые ООН в 2015 году, представляют собой систему из 17 взаимосвязанных глобальных задач, охватывающих широкий спектр проблем — от ликвидации нищеты и голода до борьбы с изменением климата и сохранения экосистем. Автоматическое соотнесение новостных сообщений с конкретными ЦУР позволяет оценить, какие аспекты устойчивого развития находятся в фокусе общественного внимания в различных регионах, а анализ тональности этих сообщений даёт возможность интерпретировать эмоциональную окраску общественной реакции.

Интеграция методов обучения для тематической классификации с методами анализа тональности позволяет создать комплексный инструмент оценки общественных настроений в контексте устойчивого развития. Модели на основе архитектуры BERT демонстрируют высокую точность в задачах многоклассовой классификации текстов благодаря способности учитывать двунаправленный контекст слов, в то время как словарные методы анализа тональности не требуют длительного обучения на размеченных данных и обеспечивают прозрачную интерпретацию результатов.

Целью данной курсовой работы является оценка тональности новостных сообщений регионов Российской Федерации, классифицированных по целям устойчивого развития. Для достижения поставленной цели необходимо решить следующие задачи:

- осуществить выбор классификационной модели;
- выполнить классификацию собранных текстовых данных по 17 целям устойчивого развития с помощью выбранной модели;
- провести анализ тональности классифицированных текстов;

- сопоставить распределение и тональность текстов по категориям ЦУР в разрезе регионов и лет;
- выявить тренды тональности экономической повестки по регионам Российской Федерации.

Курсовая работа состоит из двух разделов. В первом разделе рассматриваются методы классификации текстов: от классических алгоритмов машинного обучения до глубоких нейросетевых архитектур, включая модель BERT и её русскоязычную модификацию RuBERT; также описываются словарные методы анализа тональности и подходы к категоризации целей устойчивого развития. Во втором разделе представлены результаты классификации региональных новостных данных с помощью модели RuBERT, анализ тональности размеченных текстов по категориям ЦУР и интерпретация полученных результатов.

# **1 Обзор методов классификации текстовых сообщений**

## **1.1 Классические методы классификации текстов**

Классификация текстов — задача автоматического присвоения категорий текстовым данным — прошла длинный путь развития, отражающий эволюцию технологий обработки естественного языка. Первые подходы к решению этой задачи основывались на ручном создании экспертных правил, таких как поиск ключевых слов или использование регулярных выражений. Однако такие системы были трудоёмкими в поддержке, плохо адаптировались к новым данным и не учитывали контекстную неоднозначность.

С развитием машинного обучения фокус сместился на статистические методы. Тексты стали представляться в виде числовых векторов: модель «мешка слов» (Bag of Words), где учитывалась частота слов, или TF-IDF, где вес слова зависел от его важности в документе и корпусе. Эти представления использовались в сочетании с классическими алгоритмами классификации.

Одним из наиболее интерпретируемых методов является дерево решений (Decision Tree). Дерево решений представляет собой иерархическую структуру, в которой каждый внутренний узел соответствует проверке определённого признака (например, наличия конкретного слова в тексте), каждая ветвь — результату проверки, а каждый лиственный узел — итоговому классу. Применительно к анализу тональности, построение дерева решений начинается с преобразования текста в числовые признаки, после чего на каждом шаге выбирается атрибут, наиболее эффективно разделяющий данные по целевой переменной. В качестве критерия разделения чаще всего используется индекс Джини или энтропия. Преимуществом деревьев решений является их наглядность и возможность проследить, какие именно признаки повлияли на итоговое решение.

Для повышения точности и устойчивости деревьев решений применяются ансамблевые методы, в частности случайный лес (Random Forest) [?]. Случайный лес строит множество независимых деревьев решений на различных подвыборках исходных данных с использованием случайного подмножества признаков. Итоговое решение принимается большинством голосов (для классификации) или усреднением (для регрессии). За счёт усреднения ошибок нескольких моделей случайный лес менее склонен к переобучению, чем одиночное дерево решений, и демонстрирует более высокое качество

классификации.

Другими распространёнными классическими методами являются метод опорных векторов (SVM) и наивный байесовский классификатор. SVM строит разделяющую гиперплоскость в пространстве признаков, максимизирующую зазор между классами, и эффективен при работе с разреженными данными, характерными для текстовой векторизации TF-IDF. Наивный байесовский классификатор основан на теореме Байеса с предположением о независимости признаков и, несмотря на простоту, показывает приемлемые результаты в задачах бинарной классификации текстов.

Однако все перечисленные классические подходы имеют принципиальные ограничения. Во-первых, представление текста в виде «мешка слов» игнорирует порядок слов и синтаксические связи между ними, что приводит к потере контекстуальной информации. Во-вторых, классические методы не способны улавливать семантическую близость слов — например, слова «экономика» и «хозяйство» будут рассматриваться как независимые признаки, несмотря на смысловую связь. В-третьих, для достижения высокого качества требуется тщательный ручной отбор признаков (feature engineering) и настройка параметров модели под каждую конкретную предметную область [?].

Стремление преодолеть указанные ограничения привело к развитию нейросетевых подходов, в частности архитектур глубокого обучения, способных автоматически извлекать иерархические признаки из текста и учитывать контекст.

## **1.2 Архитектура BERT**

Появление распределённых представлений слов (word embeddings), таких как Word2Vec, GloVe и FastText, стало важным шагом вперёд. Эти методы кодировали слова в плотные векторы фиксированной размерности, сохраняющие семантические связи: например, векторное представление слова «король» приближалось к разности векторов «королева» и «женщина». Однако статические эмбединги имели ключевой недостаток — они не могли отражать многозначность слов, кодируя слово «ключ» одинаково в контекстах «ключ от двери», «музыкальный ключ» и «криптографический ключ».

Следующим этапом стали рекуррентные нейронные сети (RNN) и их усовершенствованная версия — сети с долгой краткосрочной памятью (LSTM), которые обрабатывали текст как последовательность, учитывая зависимости

между словами. Однако эти архитектуры страдали от проблемы «исчезающих градиентов» при работе с длинными текстами и, будучи однонаправленными, учитывали только левый контекст каждого слова.

Радикальное изменение принесла архитектура трансформеров, представленная в 2017 году [?]. Ключевым нововведением стал механизм самовнимания (self-attention), позволяющий каждому токеноу в последовательности напрямую взаимодействовать с любым другим токеном, независимо от их относительного положения. Технически это реализуется через три обучаемые матрицы: запросов ( $Q$ ), ключей ( $K$ ) и значений ( $V$ ). Веса внимания вычисляются через функцию softmax от скалярных произведений запросов и ключей:

$$\text{Attention}(Q, K, V) = \text{softmax} \left( \frac{QK^T}{\sqrt{d_k}} \right) V, \quad (1)$$

где  $d_k$  — размерность векторов ключей.

Модель BERT (Bidirectional Encoder Representations from Transformers) [?], разработанная Google в 2018 году, использует исключительно кодирующую часть трансформера и достигает прорывных результатов благодаря двунаправленному анализу контекста. В отличие от предшествующих моделей, где контекст накапливался только слева направо, BERT одновременно учитывает как предшествующий, так и последующий контекст каждого слова, что критически важно для разрешения лексической многозначности.

Каждый слой кодировщика BERT состоит из блока multi-head attention и полносвязной прямой сети (feed-forward network). Multi-head attention позволяет нескольким модулям внимания работать параллельно, изучая различные типы зависимостей в тексте — синтаксические, семантические, лексические. Выходы модулей конкатенируются и проецируются в исходную размерность. После каждой операции применяются остаточные связи (residual connections) и нормализация слоя (layer normalization), обеспечивающие стабильность обучения глубоких сетей.

Предобучение BERT осуществляется на двух задачах. Первая — Masked Language Modeling (MLM), где 15% случайных токенов в тексте заменяются маской [MASK], а модель обучается их восстанавливать по контексту. Вторая — Next Sentence Prediction (NSP), где модель определяет, действительно ли одно предложение следует за другим в оригинальном

тексте. Этот двухэтапный процесс позволяет BERT освоить как лексико-семантические, так и дискурсивные закономерности языка.

Для задач классификации используется выходное представление специального токена [CLS], добавляемого в начало каждой последовательности. Считается, что этот вектор агрегирует информацию обо всём документе, и к нему добавляется классификатор — обычно один или несколько полносвязных слоёв, дообучаемых на целевом наборе данных.

Ключевым преимуществом BERT является возможность дообучения (fine-tuning): модель, предобученная на больших корпусах текстов (Wikipedia, новостные статьи), может быть быстро адаптирована к узкоспециализированной задаче даже при ограниченном размере размеченной выборки. Это существенно сокращает затраты на разметку данных и делает технологию доступной для научных и прикладных проектов.

### **1.3 RuBERT: русскоязычная модификация BERT**

Для обработки русскоязычных текстов особый интерес представляет модель RuBERT (DeepPavlov/rubert-base-cased) [?] — специализированная версия BERT, дообученная на обширных корпусах русскоязычных текстов, включая новостные статьи, материалы Wikipedia и данные социальных медиа. RuBERT наследует архитектуру оригинального BERT (178 миллионов параметров, 12 слоёв кодировщика) и использует токенизацию WordPiece, адаптированную для морфологически сложного русского языка.

В сравнительных экспериментах, проведённых в работе [ссылка на работу Никиты] RuBERT показал наилучшие результаты среди трёх протестированных моделей (Multilingual BERT, RuBERT, XLM-RoBERTa) при решении задачи классификации текстов по целям устойчивого развития, достигнув F1-меры 0.884 на объединённой обучающей выборке. Это превосходит показатели Multilingual BERT (F1=0.878) и XLM-RoBERTa (F1=0.850) и подтверждает преимущество специализированных языковых моделей для обработки локализованного контента [?]. Архитектура модели включает дополнительный классификатор: промежуточный полносвязный слой с 256 нейронами и функцией активации ReLU, слой регуляризации Dropout с вероятностью 0.3 и выходной слой с 17 нейронами и активацией softmax, соответствующий числу классов ЦУР.



## 1.4 Словарные методы анализа тональности

Анализ тональности текстов (Sentiment Analysis) представляет собой процесс автоматического определения эмоциональной окраски текстовых данных. В области компьютерной лингвистики анализ тональности традиционно реализуется через два принципиально различных подхода: классические алгоритмы машинного обучения, требующие размеченных обучающих выборок, и словарные методы, опирающиеся на заранее составленные лексиконы тональности. Словарный подход обладает рядом преимуществ, делающих его предпочтительным в условиях отсутствия качественных обучающих данных для конкретной предметной области [?].

Словарный метод основан на использовании специализированных лингвистических ресурсов — словарей, в которых каждому слову или выражению сопоставлена оценка тональности. Для анализа русскоязычных текстов в данной работе используются два словаря: КартаСловСент и RuSentiLex.

Словарь RuSentiLex [?] представляет собой русскоязычный лексикон для анализа тональности текстов. В нём слова и словосочетания размечены как позитивные, негативные или нейтральные. Каждая строка словаря содержит слово, часть речи, лемму (нормальную форму) и собственно тональность (positive, negative или neutral). Общий объём словаря составляет порядка 16 тысяч записей.

Словарь КартаСловСент (kartaslovsent) [?] содержит около 46 тысяч терминов и использует более детальную схему оценки: каждой лексической единице сопоставлено дробное значение тональности (например, 0.08 для нейтрально-позитивных слов и  $-0.68$  для явно негативных), а также дополнительные метрики: доля разметчиков, отнёсших слово к позитивному, негативному и нейтральному классам. Такой подход позволяет более гибко учитывать неоднозначность эмоциональной окраски слов.

Алгоритм словарного анализа тональности включает следующие этапы. На первом этапе производится предварительная обработка текста: удаление пунктуации, специальных символов и стоп-слов (часто встречающихся слов, не несущих смысловой нагрузки). На втором этапе текст разбивается на отдельные слова, каждое из которых подвергается лемматизации — приведению к нормальной форме с помощью морфологического анализатора

(в реализации используется библиотека `rumorphy3`). Лемматизация критически важна для русского языка с его развитой морфологией, так как позволяет сопоставить словарной записи любую словоформу (например, «экономический», «экономического», «экономическому» будут приведены к лемме «экономический» для поиска в словаре). На третьем этапе для каждого слова осуществляется поиск в словаре тональности: если лемма найдена, соответствующее значение тональности добавляется к суммарной оценке текста. Итоговая тональность текста определяется как среднее арифметическое значений всех найденных в словаре слов. Текст классифицируется как позитивный, если средняя оценка превышает пороговое значение 0.2; в противном случае — как негативный.

Преимуществом словарного подхода является отсутствие необходимости в размеченной обучающей выборке и высокая интерпретируемость результатов: всегда можно проследить, какие именно слова определили итоговую оценку тональности. Кроме того, словарный метод легко адаптируется к различным предметным областям путём дополнения словаря доменно-специфичными терминами.

### 1.5 Группировка целей устойчивого развития в категории

Принятые ООН 17 целей устойчивого развития охватывают три ключевых измерения устойчивого развития [?]:

- экономическое развитие — ликвидация бедности (ЦУР 1), обеспечение достойной работы и экономического роста (ЦУР 8), создание устойчивой инфраструктуры и инноваций (ЦУР 9);
- социальное развитие — обеспечение здорового образа жизни (ЦУР 3), качественное образование (ЦУР 4), гендерное равенство (ЦУР 5);
- экологическая устойчивость — борьба с изменением климата (ЦУР 13), сохранение экосистем суши (ЦУР 15) и океанов (ЦУР 14).

В рамках данной работы для анализа региональной повестки используется расширенная группировка всех 17 целей в три категории:

- **Социальные:** ЦУР 1 (ликвидация нищеты), 2 (ликвидация голода), 3 (здоровье), 4 (образование), 5 (гендерное равенство), 6 (чистая вода и санитария), 7 (доступная энергия), 11 (устойчивые города), 16 (мир и правосудие);
- **Экономические:** ЦУР 8 (экономический рост и занятость), 9

(инфраструктура и инновации), 10 (сокращение неравенства), 12 (ответственное потребление и производство), 17 (партнёрство в интересах устойчивого развития);

- **Экологические:** ЦУР 13 (борьба с изменением климата), 14 (сохранение морских экосистем), 15 (сохранение экосистем суши).

Данная категоризация позволяет агрегировать результаты классификации на более высоком уровне и сопоставлять распределение общественного внимания по трём макронаправлениям устойчивого развития в различных регионах Российской Федерации.

## **2 Классификация текстовых сообщений в соответствии с целями устойчивого развития**

### **2.1 Применение BERT-модели для тематической классификации**

Для классификации текстовых данных по целям устойчивого развития использована модель RuBERT, обученная в рамках бакалаврской работы Морозова Н. А. [?]. Модель построена на архитектуре DeepPavlov/rubert-base-cased с добавлением классификатора: промежуточный полносвязный слой (256 нейронов, функция активации ReLU), слой регуляризации Dropout (вероятность 0.3) и выходной слой с 17 нейронами и функцией активации softmax. Обучение проводилось на объединённой выборке из двух корпусов: OSDG Community Dataset и SDGi Corpus, общим объёмом около 27 000 текстов после предобработки, с использованием оптимизатора Adam (learning rate =  $2 \times 10^{-5}$ , batch size = 16) в течение 6 эпох. Модель достигла F1-меры 0.884 на тестовой выборке, что является лучшим результатом среди рассмотренных архитектур [?].

Исходные текстовые данные собраны из новостных сообществ социальной сети «ВКонтакте» с использованием API VK. Сбор производился путём поиска сообществ по названию города (Астрахань, Омск, Казань) с последующим извлечением постов из найденных сообществ за заданный временной интервал. Для фильтрации релевантных сообщений применялся механизм поиска по ключевым словам: текст каждого поста проверялся на соответствие регулярному выражению, построенному на основе заданного пользователем набора ключевых слов с применением стемминга (выделения основы слова) для обеспечения морфологической вариативности поиска. Ключевые слова подбирались таким образом, чтобы охватить широкий спектр тем, релевантных целям устойчивого развития — от вопросов экономического развития и социальной политики до экологической проблематики.

Данные охватывают три региона Российской Федерации за период 2020–2025 годов и включают 9 765 текстовых сообщений, распределённых по 18 файлам. Характеристика исходного набора представлена в таблице 1.

Таблица 1 – Характеристика исходного набора данных

| Регион               | 2020 | 2021 | 2022 | 2023 | 2024 | 2025 |
|----------------------|------|------|------|------|------|------|
| Астраханская область | 945  | 716  | 953  | 903  | 523  | 683  |
| Омская область       | 323  | 238  | 350  | 329  | 358  | 337  |
| Татарстан            | 262  | 741  | 595  | 516  | 369  | 624  |

Каждый текст был подан на вход модели RuBERT, которая сформировала для него предсказание класса ЦУР в формате «SDG N» (где N — номер цели от 1 до 17) и значение уверенности (confidence) в интервале от 0 до 1. Для последующего анализа использовались все предсказания, включая тексты с уверенностью ниже порогового значения, поскольку модель демонстрирует высокое общее качество классификации.

## 2.2 Применение словарных методов для анализа тональности

Для оценки тональности классифицированных текстов применены словарные методы с использованием двух лексиконов: КартаСловСент и RuSentiLex. Выбор двух независимых словарей обусловлен различиями в их структуре и принципах разметки, что позволяет сопоставить результаты и оценить устойчивость выводов к выбору конкретного лексикона.

Алгоритм обработки для каждого файла включал следующие шаги. На первом этапе производилась загрузка SDG-размеченных данных (столбцы «text», «predicted\_class», «confidence»). На втором этапе каждому тексту сопоставлялась одна из трёх категорий ЦУР (социальные, экономические, экологические) в соответствии с классификацией, описанной в разделе 1.5. На третьем этапе текст подвергался лемматизации с помощью морфологического анализатора rymorphy3: для каждого слова определялась его нормальная форма, после чего из текста удалялись стоп-слова. На четвёртом этапе для каждой леммы выполнялся поиск в словаре тональности, и на основе найденных оценок вычислялась средняя тональность текста. Текст классифицировался как позитивный, если средняя оценка превышала порог 0.2 (для КартаСловСент) или была положительной (для RuSentiLex); в противном случае — как негативный.

Результаты обработки агрегировались по следующим разрезам: регион, год, категория ЦУР (социальные / экономические / экологические), словарь

(КартаСловСент / RuSentiLex). Для каждой комбинации фиксировалось общее количество текстов, количество текстов с найденной тональностью и доля позитивных текстов.

## 2.3 Апробация для отдельных регионов

Обработка 9 765 текстов по двум словарям позволила получить детальную картину распределения общественного внимания по категориям целей устойчивого развития и его эмоциональной окраски для трёх регионов России.

### 2.3.1 Распределение текстов по категориям ЦУР

Результаты группировки предсказаний модели RuBERT по трём категориям ЦУР представлены в таблице 2. Во всех трёх регионах доминирует социальная повестка, составляющая в среднем 74.5% от общего числа сообщений. Наибольшая доля социальных ЦУР зафиксирована в Астраханской области (в среднем 84.0%), наименьшая — в Татарстане (68.3%). Экономическая категория в среднем составляет 15.4%, однако её доля заметно варьируется: в Омской области она достигает 22.8% (с пиком 45.7% в 2025 году), тогда как в Астраханской области — лишь 7.2%. Экологическая повестка наиболее выражена в Татарстане (15.3%) и наименее — в Омской области (6.1%).

Таблица 2 – Среднее распределение текстов по категориям ЦУР (2020–2025)

| Регион               | Всего текстов | Социальные, % | Экономические, % | Экологические, % |
|----------------------|---------------|---------------|------------------|------------------|
| Астраханская область | 4 723         | 84.0          | 7.2              | 10.8             |
| Омская область       | 1 935         | 71.2          | 22.8             | 6.1              |
| Татарстан            | 3 107         | 68.3          | 16.4             | 15.3             |
| <b>Все регионы</b>   | <b>9 765</b>  | <b>74.5</b>   | <b>15.4</b>      | <b>10.1</b>      |

На рисунке 1 представлено распределение текстов Астраханской области по категориям ЦУР в динамике по годам. Аналогичные диаграммы для Омской области и Татарстана приведены на рисунках 2 и 3 соответственно.




Рисунок 1 – Распределение текстов по категориям ЦУР, Астраханская область




Рисунок 2 – Распределение текстов по категориям ЦУР, Омская область




Рисунок 3 – Распределение текстов по категориям ЦУР, Татарстан

### 2.3.2 Тональность по категориям ЦУР

Результаты анализа тональности с использованием словаря КартаСловСент представлены в таблице 3. Экономическая категория демонстрирует наиболее высокую долю позитивных текстов во всех трёх регионах: от 88.7% в Татарстане до 92.7% в Омской области. Социальная повестка характеризуется умеренно-позитивной тональностью (от 74.1% в Татарстане до 85.1% в Омской области). Экологическая категория, напротив, показывает наименьшую долю позитива: от 46.6% в Татарстане до 75.2% в Астраханской области.

Таблица 3 – Средняя доля позитивных текстов по категориям ЦУР и регионам (КартаСловСент)

| Регион               | Социальные, % | Экономические, % | Экологические, % |
|----------------------|---------------|------------------|------------------|
| Астраханская область | 78.9          | 91.4             | 75.2             |
| Омская область       | 85.1          | 92.7             | 59.4             |
| Татарстан            | 74.1          | 88.7             | 46.6             |

Результаты, полученные с использованием словаря RuSentiLex (таблица 4), подтверждают общую закономерность: экономическая категория остаётся наиболее позитивной (87.6–91.4%), экологическая — наименее (52.6–77.9%). Некоторое расхождение в абсолютных значениях между словарями



объясняется различиями в их структуре: КартаСловСент использует дробные оценки и более детальную схему разметки, в то время как RuSentiLex оперирует дискретными значениями ( $-1, 0, 1$ ).

Таблица 4 – Средняя доля позитивных текстов по категориям ЦУР и регионам (RuSentiLex)

| Регион               | Социальные, % | Экономические, % | Экологические, % |
|----------------------|---------------|------------------|------------------|
| Астраханская область | 67.1          | 89.5             | 77.9             |
| Омская область       | 84.9          | 91.4             | 66.0             |
| Татарстан            | 66.2          | 87.6             | 52.6             |

На рисунке 4 показана динамика тональности по категориям ЦУР для Астраханской области. Экономическая повестка на протяжении всего периода сохраняет высокий уровень позитивности (в среднем выше 90%), в то время как социальная и экологическая категории демонстрируют более выраженные колебания.




Рисунок 4 – Динамика тональности по категориям ЦУР, Астраханская область (КартаСловСент)

### 2.3.3 Межрегиональное сравнение экономической повестки

Особый интерес представляет сопоставление тональности экономической повестки между регионами (рисунок 5). По данным словаря КартаСловСент, все

три региона демонстрируют стабильно высокую позитивность экономических сообщений на уровне 85–95%. Омская область лидирует по данному показателю (92.7%), за ней следуют Астраханская область (91.4%) и Татарстан (88.7%). Высокая позитивность экономической повестки может объясняться преобладанием в новостных сообщениях материалов о развитии инфраструктуры, инвестиционных проектах и мерах государственной поддержки, которые, как правило, подаются в позитивном ключе.




Рисунок 5 – Сравнение тональности экономической повестки по регионам (КартаСловСент)

Полученные результаты демонстрируют, что интеграция BERT-классификации по целям устойчивого развития со словарным анализом тональности позволяет получить многомерную картину общественной повестки регионов. Экономическая тематика, несмотря на относительно невысокую долю в общем объёме сообщений (15.4%), характеризуется наиболее позитивной тональностью, что может свидетельствовать о конструктивном характере обсуждения экономических вопросов в региональных новостных сообществах.

## **СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ**