МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«САРАТОВСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ИМЕНИ Н. Г. ЧЕРНЫШЕВСКОГО»

УТВЕРЖДАЮ
Зав. кафедрой дискретной
математики и информационных
технологий
доцент, к. ф.-м. н.
_____ Л. Б. Тяпаев

ОТЧЕТ О ПРАКТИКЕ

студента 1 курса 171 группы факультета КНиИТ
направления 09.04.01 — Информатика и вычислительная техника
Тарана Евгения Вячеславовича

вид практики: учебная
кафедра: дискретной математики и информационных технологий
курс: 1
семестр: 1
продолжительность: рассредоточенная, с 01.09.25 по 30.12.25

Руководитель практики,
доцент, к. э. н. _____ Г. Ю. Чернышова

Саратов 2025

Тема практики:
«Анализ подходов на основе Text Mining для оценки устойчивости развития регионов»

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 4
1 Подходы к оценке устойчивого развития с помощью методов машинного обучения 5
2 Применение Text Mining в комплексной оценке показателей устойчивого развития 9
ЗАКЛЮЧЕНИЕ 20
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 21

ВВЕДЕНИЕ

В современном мире объёмы неструктурированных текстовых данных, формируемых в цифровой среде, растут экспоненциально. Новостные агрегаторы, социальные сети, корпоративные отчёты, аналитические обзоры и открытые государственные данные содержат в себе информацию, критически важную для оценки социально-экономического состояния регионов, компаний и общества в целом. Однако извлечение из этих массивов текстов объективных показателей и прогнозных трендов представляет собой сложную междисциплинарную задачу, находящуюся на стыке компьютерной лингвистики, анализа данных и экономической науки.

Актуальность данного направления обусловлена потребностью в автоматизированных, масштабируемых и точных инструментах, способных оперативно анализировать большие текстовые корпуса для поддержки принятия решений. Традиционные методы ручной обработки и экспертной оценки становятся недостаточными в условиях высокой динамики информационных потоков. В этой связи методы Text Mining открывают новые возможности для комплексной, количественной и качественной оценки социально-экономических явлений.

Целью учебной практики является анализ моделей и методов для задачи комплексной оценки показателей устойчивого развития.

Для достижения поставленной цели формулируются следующие задачи:

1. Сравнение подходов к сбору и предобработке неструктурированных текстовых данных;
2. рассмотрение современных моделей и методов с точки зрения их применимости для оценки устойчивого развития;
3. выработка рекомендаций по применению рассмотренных методов при разработке приложения для комплексного определения уровня устойчивого развития.

1 Подходы к оценке устойчивого развития с помощью методов машинного обучения

Вопросы устойчивого развития в последние десятилетия приобрели статус одной из ключевых тем глобальной социально-экономической повестки. В 2015 году Генеральной Ассамблеей ООН была принята Повестка дня в области устойчивого развития на период до 2030 года, центральным элементом которой стали 17 Целей устойчивого развития (ЦУР) [1]. Эти цели представляют собой комплексную систему ориентиров, направленных на сбалансированное развитие экономической, социальной и экологической сфер, а также на снижение неравенства, повышение качества жизни и обеспечение долгосрочной устойчивости развития на глобальном, национальном и региональном уровнях.

Цели устойчивого развития выполняют не только нормативную, но и аналитическую функцию, формируя основу для мониторинга, сравнения и оценки прогресса различных стран и регионов. Традиционно оценка достижения ЦУР базируется на системе количественных статистических индикаторов, разрабатываемых международными организациями и национальными статистическими службами.

В этой связи в научных исследованиях последних лет все большее внимание уделяется альтернативным и дополняющим методам оценки устойчивого развития, основанным на анализе неструктурированных данных, прежде всего текстовой информации. Научные публикации, корпоративные отчёты, медиаконтент и официальные стратегические документы рассматриваются как источники информации, позволяющие выявлять не только количественные показатели, но и доминирующие нарративы, приоритеты и интерпретации процессов устойчивого развития [2].

Так например в работе [3] представлен сравнительный анализ прогресса стран в достижении Целей устойчивого развития на основе системы количественных индикаторов. Авторы используют агрегированные показатели, формируемые из официальных статистических данных для сопоставления уровней устойчивого развития различных государств. Особое внимание уделяется тому, как выбор методов нормализации и агрегирования влияет на результаты оценки. Показано, что итоговые интегральные индексы достижения ЦУР существенно зависят от используемых методологических подходов, что указывает на необходимость осторожного подхода к их интерпретации при анализе экономического

развития.

Исследование [4] ориентировано на анализ вклада Целей устойчивого развития в экономический рост и национальное развитие на примере отдельной страны. В работе рассматривается взаимосвязь между реализацией ЦУР и динамикой ключевых макроэкономических показателей, таких как валовой внутренний продукт, уровень занятости и социальное неравенство. Используемый подход сочетает анализ статистических данных с изучением национальных стратегических документов и отчётов по устойчивому развитию. Результаты исследования указывают на наличие корреляций между прогрессом по отдельным ЦУР и социально-экономическими показателями, однако также выявляют ограничения, связанные с институциональными факторами и качеством доступных данных.

В статье [5] предлагается расширенный метод оценки устойчивого развития, основанный на интеграции показателей ЦУР в концепцию жизненного цикла. Авторы рассматривают экономическое развитие не только в макроэкономическом контексте, но и на уровне отдельных производственных систем и процессов. Предложенный подход позволяет учитывать взаимосвязь экономических, экологических и социальных факторов на разных этапах жизненного цикла продукции или инфраструктурных проектов. Работа подчёркивает значимость комплексных индикаторов и междисциплинарных методов для более точной оценки устойчивости развития.

В статье [6] рассматривается задача мониторинга устойчивого развития на региональном уровне на основе анализа медиадискурса. В качестве исходной предпосылки используется положение о том, что традиционные системы оценки устойчивого развития, базирующиеся на статистических индикаторах, характеризуются высокой инерционностью и не всегда позволяют оперативно фиксировать изменения социально-экономической и экологической повестки. В этом контексте региональные средства массовой информации рассматриваются как источник актуальных, контекстно насыщенной данных, отражающих как институциональные приоритеты, так и общественное восприятие процессов развития.

Методологическая основа исследования опирается на применение методов Text Mining к корпусу региональных новостных публикаций, связанных с тематикой устойчивого развития. На этапе предварительной обработки тексто-

вых данных используются процедуры очистки, токенизации, лемматизации и удаления стоп-слов, что обеспечивает унификацию текстов и снижение уровня шумов. Для выявления значимых лексических единиц применяется взвешивание терминов с использованием показателя TF–IDF, позволяющего выделить ключевые маркеры устойчивого развития в региональном медиаконтенте.

В работе [7] рассматривается взаимосвязь между корпоративной устойчивостью и достижением Целей устойчивого развития на основе анализа научного и корпоративного дискурса. Исследование направлено на выявление ключевых тематических направлений, формирующих современное понимание роли бизнеса в устойчивом развитии, а также на систематизацию научных исследований в данной области.

Методологическая основа работы базируется на библиометрическом анализе и методах тематического моделирования. В качестве исходных данных используется корпус научных публикаций, отобранных из международных библиографических баз данных по ключевым словам, связанным с корпоративной устойчивостью и Целями устойчивого развития. Предварительная обработка текстов включает стандартные процедуры очистки, нормализации и лемматизации, что обеспечивает сопоставимость текстовых данных и корректность последующего анализа [8].

Для выявления латентной тематической структуры корпуса применяется вероятностное тематическое моделирование на основе алгоритма LDA. В результате формируются тематические кластеры, отражающие основные направления исследований, включая экологическую ответственность бизнеса, социальные аспекты устойчивости, корпоративное управление и вклад компаний в реализацию ЦУР. Тематические модели позволяют проследить структуру научного дискурса и определить доминирующие и периферийные направления исследований. Дополнительно в работе проводится анализ эволюции выявленных тематических направлений во времени.

Основные результаты исследования свидетельствуют о том, что методы Text Mining и тематического моделирования являются эффективным инструментом для систематизации и анализа больших массивов текстовой информации, связанной с устойчивым развитием. Использование тематических моделей позволяет выявлять скрытые закономерности в научных публикациях и формировать целостное представление о структуре исследовательского поля.

Ведущая значимость работы заключается в демонстрации возможностей применения интерпретируемых методов Text Mining для анализа комплексных социально-экономических процессов, связанных с устойчивым развитием.

Рассмотренные исследования демонстрируют, что современные подходы к оценке устойчивого развития в контексте Целей устойчивого развития преимущественно опираются на систему формализованных индикаторов и агрегированных статистических показателей. Несмотря на их широкое распространение и нормативную значимость, такие методы обладают ограниченной способностью отражать качественные аспекты социально-экономических процессов, а также динамику общественного и институционального дискурса.

В этой связи возрастает интерес к анализу неструктурированных текстовых данных как дополнительному источнику информации, позволяющему выявлять латентные приоритеты, нарративы и взаимосвязи, не фиксируемые традиционной статистикой. Именно эту задачу решают подходы на основе Text Mining, применение которых в контексте оценки устойчивого развития рассматривается в дальнейшем разделе работы.

2 Применение Text Mining в комплексной оценке показателей устойчивого развития

Исследовательская работа [9] наглядно демонстрирует, как методы Text Mining (NLP), в частности техника документных эмбеддингов (doc2vec), реализованная в библиотеке Gensim [10], и сетевой анализ, могут быть применены для преобразования неструктурированных текстовых массивов — в их случае ежегодных отчетов ООН — в количественные метрики для комплексной оценки. Они решают задачу не прямой оценки показателей, а оценки взаимосвязей между концептуальными областями (Целями устойчивого развития), что является более высоким уровнем аналитики. Их подход превращает качественный политический дискурс в взвешенный граф взаимосвязей, выявляя структурные разрывы (например, между экологическими и социальными блоками целей) и неочевидные семантические кластеры.

Важной деталью исследования стало применение алгоритма Лювена. Алгоритм Лувена — метод обнаружения сообществ в сетях, оптимизирующий метрику модулярности для выявления групп узлов с плотными внутренними и слабыми внешними связями [11].

В исследовании алгоритм применён к сети, построенной на основе косинусного сходства векторных представлений отчётов ООН по 17 Целям устойчивого развития (ЦУР). Целью было выявление кластеров ЦУР, семантически близких в политическом дискурсе.

Анализ выявил четыре кластера. Экологические ЦУР (12, 13, 14, 15) образовали отдельное сообщество. Социально-экономические цели (7, 8, 9, 10, 17) сгруппировались вместе. Цели по водоснабжению и городам (6, 11) составили третий кластер. Социальные цели (1, 2, 3, 4, 5, 16) сформировали четвёртый.

Основной вывод, полученный с помощью алгоритма, заключается в том, что экологические ЦУР, в особенности ЦУР 13 (климат), дискурсивно обособлены от социально-экономического блока в документах ООН. Это указывает на рассогласование между экологической и социально-экономической составляющими в международном политическом дискурсе об устойчивом развитии.

Можно заключить, что рассматриваемая работа [9] предоставляет не только алгоритмические решения, но и законченный сценарий применения Text Mining для аналитики социально-экономического контента.

Статья [12] является прямым и практически ориентированным продолже-

нием логики предыдущего обзора, смещая фокус с анализа структурных взаимосвязей между целями на оценку тональности и текущего политического нарратива в текстах, непосредственно отражающих национальный прогресс — Добровольных национальных обзорах (ДНО) по ЦУР.

Основная ценность этой работы заключается в демонстрации применения более сложной и контекстуально зависимой методики Text Mining — Aspect-Based Sentiment Analysis (ABSA, анализ тональности на основе аспектов). Если предыдущее исследование [9] использовало doc2vec для макросемантического сравнения документов, то здесь авторы решают задачу тонкого, целевого извлечения тональности по каждому из 17 ЦУР в пределах одного документа. Это соответствует реальной потребности аналитика: понять не общее настроение отчета, а конкретную оценку, которую страна дает своему прогрессу в области ликвидации голода (ЦУР 2) или обеспечения гендерного равенства (ЦУР 5).

Статья предлагает применение аспектно-ориентированного анализа тональности (ABSA) к корпусу из 232 Добровольных национальных обзоров (ДНО) для получения количественных оценок тональности, с которой 166 стран описывают прогресс по каждой из 17 Целей устойчивого развития (ЦУР). ABSA представляет собой метод анализа текста, предназначенный для определения эмоциональной окраски (позитивной, негативной, нейтральной) не документа в целом, а отдельных его аспектов (аспектов) или сущностей. В данном исследовании сущностями выступали 17 ЦУР. Для реализации ABSA была использована модель на основе BERT, обученная на размеченных отчётах ООН о прогрессе по ЦУР (N=2079 предложений). Эта модель классифицирует каждое предложение ДНО: определяет, к какой ЦУР оно относится, и оценивает тональность высказывания об этом прогрессе. Полученные оценки агрегировались в сентимент-скор для каждой пары страна-ЦУР в диапазоне от -1 до +1.

Для выявления группировки стран по схожести их нарратива применялся алгоритм t-SNE, проецирующий 17-мерные вектора сентимент-скоров в двумерное пространство. Сравнение сентимент-скоров с официальными индексами ЦУР ООН проводилось с использованием коэффициента корреляции Кендалла.

Результаты кластеризации с помощью t-SNE показали, что развитые страны (DM) формируют плотную группу с относительно однородной тональностью отчётов. Наименее развитые страны (LDC) и страны с формирующимися рынками (FM) демонстрируют значительный разброс, что указывает на большую

вариативность их нарративов и, возможно, траекторий развития. Авторы отмечают, что развитые страны склонны к более критической тональности даже при высоких объективных показателях, в то время как LDC и FM страны чаще используют позитивную тональность.

Особенно важно отметить комплексный подход авторов к подготовке данных, что часто является ключевым вызовом в прикладных проектах. Они детально описывают пайплайн обработки: от парсинга неструктурированных PDF с использованием модели VILA и перевода текстов с помощью MarianMT до очистки и аннотирования тренировочного корпуса на основе отчетов ООН. Этот опыт крайне важен для проработки архитектурного раздела работы, где необходимо предусмотреть этапы предобработки разнородных текстовых данных.

Результаты анализа содержат несколько ключевых выводов. Во-первых, выявлен так называемый «парадокс прогресса»: страны с формирующимся рынком и наименее развитые страны склонны давать более позитивные оценки, в то время как развитые экономики, несмотря на высокие объективные показатели, часто более самокритичны в своих ДНО. Во-вторых, с помощью визуализации многомерных данных (t-SNE) авторы показали, что развитые страны образуют плотные кластеры со схожим нарративом, в то время как отчеты развивающихся стран более разнородны. Это указывает на возможность автоматического выявления групп стран со схожими траекториями и проблемами. В-третьих, и это, возможно, самый значимый вывод для интерпретации подобных данных, корреляция между тональностью отчета и официальным индексом ЦУР оказалась слабой и неоднозначной. Сильная положительная связь наблюдалась лишь для ЦУР 2 и 11, а для ЦУР 5 связь была отрицательной.

Это подчеркивает, что текстовые отчеты отражают не столько объективный прогресс, сколько национальный нарратив, политический контекст и стиль коммуникации, что требует крайне осторожной интерпретации результатов автоматического анализа.

С методологической точки зрения, данная статья может служить ориентиром и источником возможных усовершенствований. Авторы отмечают ограничения, связанные с переводом текстов и отсутствием единого шаблона для ДНО, что влияет на качество анализа. Для приложения это означает необходимость закладывать возможность настройки модели под конкретный стиль документов и тщательной проверки качества предподготовки. Кроме того, их работа указы-

вает на перспективное направление: комбинация методов анализа тональности и семантического моделирования может предоставить наиболее полную картину, выявляя как оценочные, так и содержательные паттерны в текстовых данных.

Таким образом, статья [12] предоставляет не только сценарий использования NLP для анализа социально-экономической политики, но и переходит от общего поиска сходства к целевому анализу тональности. Она наглядно показывает, как Text Mining позволяет деконструировать сложные политические нарративы, извлекая из них количественные метрики, при этом предостерегая от их упрощенной трактовки.

В исследовании [13] представлена автоматизированная аналитическая система TETYS (Topics Evolution That You See), предназначенная для выявления и отслеживания тематических трендов в научных публикациях, посвящённых Целям устойчивого развития (ЦУР). Основная цель работы — предложить масштабируемый метод для анализа обширных корпусов текстовых данных и визуализации динамики исследовательских интересов.

Методологической основой системы является усовершенствованный пайплайн на базе фреймворка BERTopic. Главное усовершенствование заключается в использовании для вычисления эмбеддингов (векторных представлений текстов) не стандартных моделей вроде SBERT, а большой языковой модели SFR-Embedding-2 R. Это позволяет работать с гораздо более ёмкими (4096-мерными) векторными представлениями научных абстрактов, что улучшает семантическое понимание и разделение тем.

Для обработки больших объёмов данных авторы разработали механизм оптимизации гиперпараметров, основанный на случайном поиске, который максимизирует метрику качества кластеризации DBCV (Density-Based Clustering Validation). Это позволяет эффективно находить оптимальную конфигурацию модели для каждого нового набора данных. Ещё одной важной инженерной особенностью является регистрация промежуточных моделей, которая сохраняет лучшую версию для последующего использования, нивелируя стохастическую природу алгоритма кластеризации HDBSCAN.

Система была применена к более чем 760 тысячам научных аннотаций из базы Scopus за период 2006–2023 гг., сгруппированных в пять тематических макро-областей, связанных с ЦУР. В результате было выявлено и проанализировано от 136 до 856 уникальных тем в каждой области. Авторы провели сравнение

между предложенным подходом (TETYS) и базовым вариантом (использующим модель SPECTER). Количественная оценка показала, что LLM-конфигурация демонстрирует более высокие значения метрики DBCV во всех пяти макрообластях.

Качественная ручная проверка на двух крупнейших наборах данных подтвердила, что модель на основе LLM, как правило, обеспечивает лучшую интерпретируемость, качество и разнообразие тем. В одном случае разница была статистически значимой в пользу TETYS, а в другом — обе конфигурации показали сопоставимые результаты.

Практическим итогом работы стала интерактивная веб-панель, которая позволяет исследователям изучать темы, их динамику во времени, сравнивать тренды.

Границы применения Text Mining для анализа социально-экономической и экологической повестки расширяет работа [14]. Если исследования [9, 12] фокусировались на официальных отчетах ООН или национальных обзорах, то данное исследование переводит анализ в плоскость глобального медиадискурса, используя в качестве исходных данных 135 000 новостных заголовков из 100 стран. Это демонстрирует еще один критически важный аспект — работу с динамичными, неструктурированными и массовыми источниками информации в реальном времени, что приближает задачу к потребностям современных аналитиков и политиков.

Методологически статья предлагает комплексный и воспроизводимый пайплайн, ключевыми элементами которого являются классификация с помощью большой языковой модели (GPT-3.5) и последующий статистический анализ (PCA, k-means). Использование LLM для семантического соотнесения заголовков с ЦУР вместо подхода основанном на поиске ключевых слов или заранее обученных классификаторов представляет собой современный и гибкий метод, который можно адаптировать для других тематик. Однако, как справедливо отмечают авторы, это может приводить к «сглаживанию» тематического распределения из-за доминирования широких тем. Это служит важным указанием на необходимость тщательной валидации и, возможно, использования мультилейбл-классификации для повышения точности. Последующий анализ, включающий снижение размерности и кластеризацию, формирует законченный аналитический цикл — от сырого текста до интерпретируемой типологии стран.

Значимым выводом работы является эмпирически подтвержденная сильная корреляция между структурой медиа-нарратива и макро-показателями национального развития. Авторы обнаружили, что такие индикаторы, как ИР-ЧП и индекс свободы прессы статистически значимо связаны с выделенными с помощью PCA компонентами тональности. Это трансформирует медийную тональность из субъективной характеристики в латентный индикатор институционального и коммуникационного контекста страны. В частности, кластеры, выделенные алгоритмом k-means, четко соответствуют уровню развития: кластер 1 (Западная Европа, Океания) демонстрирует последовательно позитивный и объективный тон, в то время как кластер 3 (ряд стран Африки и Ближнего Востока) характеризуется поляризованным, кризисным нарративом. Это подтверждает тезис о том, что анализ текстовых данных может выявлять не только поверхностные настроения, но и глубинное состояние общественно-политической системы.

Таким образом, статья [14] показывает, как методы Text Mining, от семантического моделирования и анализа тональности до классификации с помощью LLM, могут быть интегрированы в единую систему мониторинга и анализа сложных социально-экономических процессов через призму текстовых данных.

Статья [15] посвящена разработке и применению инструмента на основе искусственного интеллекта для автоматической классификации исследовательских проектов по целям устойчивого развития (ЦУР) и визуализации результатов. Исследование направлено на решение проблемы отсутствия автоматизированных средств для постфактумной категоризации научных публикаций и проектных заявок в соответствии с ЦУР, что в настоящее время требует трудоёмкого ручного труда и подвержено субъективным ошибкам.

В качестве методологической основы использована модель BERT, дообученная на датасете из 15 488 аннотаций научных статей португалоязычных авторов из ведущих бразильских университетов. Ключевой особенностью работы является применение техники балансировки данных с использованием генеративной модели Mixtral-8x7B для создания синтетических образцов текстов в малопредставленных классах (отдельных ЦУР), что позволило компенсировать высокий дисбаланс в исходном наборе данных. Модель оценивалась по метрикам F1-score, precision и recall, демонстрируя среднюю точность классификации выше 70% для ряда целей.

Практическим результатом исследования стала интеграция обученной модели в аналитическую панель (dashboard), разработанную на платформе Power BI. Для повышения качества классификации введён порог уверенности модели в 80%; проекты с более низкой вероятностью отнесения к конкретной ЦУР помечаются как «не относящиеся».

Работа [15] демонстрирует возможность автоматизации трудоёмкого процесса категоризации текстовой информации и её трансформации в инструмент стратегического управления. Применение генеративных моделей для аугментации данных представляет собой перспективный метод решения проблемы дисбаланса классов, актуальной для многих прикладных задач анализа текстов. Ограничения исследования связаны с вычислительной сложностью генерации синтетических данных и потенциальным смещением, вносимым искусственными образцами, а также с ориентацией модели преимущественно на бразильский исследовательский контекст.

В рамках систематического обзора исследовательских трендов, связанных с устойчивым развитием, представляет интерес работа, в которой для анализа вклада современных технологий в достижение Целей устойчивого развития (SDGs) применяются методы интеллектуального анализа текстов (Text Mining) [16]. В фокусе данного исследования находится генеративный искусственный интеллект (GenAI) — класс алгоритмов, способных к созданию нового, оригинального контента (текста, изображений, аудио, кода) путем обучения на обширных массивах данных. В отличие от традиционного аналитического ИИ, GenAI не только распознает паттерны, но и генерирует на их основе новые артефакты, что делает его мощным инструментом для инноваций в таких сферах, как здравоохранение, образование, креативные индустрии и оптимизация бизнес-процессов.

Методологической основой проведенного анализа выступил метод тематического моделирования Latent Dirichlet Allocation (LDA). LDA — это вероятностная модель коллекций дискретных данных (таких как текстовые корпуса), которая предполагает, что каждый документ представляет собой смесь небольшого числа скрытых (латентных) тем, а каждая тема описывается распределением вероятностей по словам. Авторы применили LDA к корпусу из 2162 рефератов научных статей, извлеченных из базы Scopus за период 2020–2025 гг. Эта методика позволила перейти от неструктурированного текстового массива

к количественному представлению основных исследовательских направлений в области GenAI, выявив их внутреннюю тематическую структуру.

Проведенный анализ позволил авторам идентифицировать и структурировать десять ключевых тематических кластеров, отражающих основные векторы применения GenAI. Среди них — использование технологии для аугментации медицинских изображений, создание образовательного контента, оптимизация бизнес-инноваций, обнаружение киберугроз и другие.

Основной вывод исследования заключается в демонстрации значительного преобразующего потенциала GenAI для содействия устойчивому развитию через автоматизацию, персонализацию и стимулирование инноваций. Параллельно авторы делают акцент на критических этических и социальных вызовах, сопровождающих внедрение этих технологий, таких как проблема смещения рабочих мест, алгоритмическая предвзятость, вопросы приватности данных и распространение дезинформации.

Исследование [17] представляет собой компаративный анализ публикаций в области устойчивого городского развития за период 2012–2022 годов, сочетающий систематический обзор литературы с применением методов искусственного интеллекта для классификации текстов. В работе выделяются пять ключевых измерений устойчивого городского развития: экологическое, социально-культурное, экономическое, политико-управленческое и демографическое. Выбор и валидация этих измерений осуществлены с использованием метода Дельфи с участием 30 экспертов. На основе анализа 705 статей, отобранных из Google Scholar, проведена количественная оценка исследовательских трендов по континентам и странам.

Для автоматической классификации статей по выделенным измерениям использована предобученная модель BERT, которая продемонстрировала точность 59% на основе заголовков и аннотаций. Авторы отмечают, что данный результат является приемлемым для многометочной классификации при ограниченном размере размеченного набора данных, но может быть улучшен за счёт расширения корпуса текстов.

Исследование [17] вносит вклад в область анализа подходов на основе Text Mining для оценки устойчивого развития регионов, предлагая структурированную, многомерную таксономию для категоризации исследований и эмпирически подтверждая актуальность различных аспектов устойчивости в разных

географических контекстах.

Статья [18] посвящена разработке инструмента SDG-Meter, основанного на глубоком обучении, для автоматической классификации текстов в соответствии с целями устойчивого развития. В исследовании рассматривается задача многометочной классификации, учитывающей возможность отнесения текста к нескольким ЦУР одновременно.

В качестве методологической основы выбран алгоритм BERT, который демонстрирует высокую эффективность в обработке естественного языка благодаря своей двунаправленной архитектуре, способной учитывать контекст слов в тексте [19]. В статье подробно описан процесс обучения модели, включая подготовку данных, особенности токенизации и тонкой настройки предварительно обученной модели для решения задачи классификации ЦУР. Отмечается, что модель достигла точности 98% на тестовых данных, что подтверждает её соответствие экспертной оценке.

Особое внимание уделено формированию обучающего набора данных. Вместо использования синтетически сгенерированных текстов, что применялось в более ранних исследованиях и приводило к низкому качеству и недостаточной репрезентативности, авторы обратились к веб-скрапингу статей с портала IISD SDG Knowledge Hub. Это позволило собрать корпус из 724 текстов, размеченных экспертами, со средней длиной 374 слова и средним количеством меток, равным четырем. Однако распределение ЦУР в наборе данных оказалось несбалансированным, что отражает реальную тематическую направленность публикаций в период пандемии COVID-19 и подготовки к Cop26.

Инструмент SDG-Meter реализован в виде веб-приложения с интерфейсом, позволяющим пользователям вводить текст длиной до 512 слов и получать список соответствующих ЦУР с указанием вероятности принадлежности в процентах. В ходе тестирования на пяти текстах, размеченных экспертами IISD, инструмент показал способность корректно идентифицировать основные ЦУР, включая те, которые были недостаточно представлены в обучающих данных. В некоторых случаях модель дополнительно указывала на связи с ЦУР, не отмеченные экспертами, что поднимает вопрос о возможном расширении экспертного анализа за счёт методов глубокого обучения.

В заключении отмечаются ограничения подхода, связанные с несбалансированностью данных, ограничением на длину входного текста и отсутствием

в обучении примеров текстов, не относящихся к ЦУР. Предлагаются направления для улучшения, такие как расширение и диверсификация обучающего набора, включение негативных примеров и использование более совершенных архитектур, например SMITH или CogLTX, для обработки длинных текстов.

Исследование [18] представляет интерес в контексте анализа подходов на основе Text Mining для оценки устойчивого развития, поскольку демонстрирует практическое применение современных методов обработки естественного языка для автоматизации классификации документов по ЦУР. Реализованный инструмент может способствовать снижению субъективности и временных затрат при обработке больших объёмов текстовой информации, что актуально для задач мониторинга и анализа устойчивого развития регионов.

Исследование [20] представляет интерес, поскольку оно охватывает два взаимосвязанных аспекта обработки информации: автоматизированный мониторинг текстовых данных для выявления событий и моделирование процессов для анализа их последствий. Хотя статья сфокусирована на области социальных катастроф, используемые подходы имеют методологическую ценность для более широкого спектра задач, включая оценку социально-экономических показателей.

В части, касающейся Text Mining, в работе решается задача идентификации сигналов о произошедших или потенциальных чрезвычайных ситуациях путём анализа новостных потоков в интернете на румынском языке. Предложенная методология включает подготовительный и обрабатывающий этапы. На подготовительном этапе был вручную собран и классифицирован корпус из более чем 724 новостных статей, что позволило создать контролируемый словарь (лексикон) из более чем 300 ключевых слов, относящихся к 10 категориям социальных бедствий. Отмечено, что точность классификации составила 76%, однако с ростом объёма базы данных время обработки увеличивалось пропорционально её размеру, что потребовало рассмотрения оптимизаций, например, очистки данных от нерелевантных фрагментов.

Вторая часть статьи демонстрирует применение формальных методов для моделирования процессов, а именно использование аппарата сетей Петри, в частности, обобщённых стохастических сетей Петри (GSPN), для анализа сценариев эвакуации людей при катастрофах. Авторами детально описан процесс перевода плана здания в модель сети Петри, настройка параметров переходов и

проведение количественного анализа с помощью инструмента PIPE. Результаты моделирования, такие как среднее количество людей в помещениях и анализ достижимых состояний, подтверждают адекватность модели и её пригодность для проверки свойств системы. А сама идея комбинирования Text Mining для выявления событий или трендов и последующего сценарного анализа с помощью формальных моделей является концептуальной схемой, которую можно перенести в экономическую и социальную сферу.

ЗАКЛЮЧЕНИЕ

Современные подходы на основе обработки естественного языка, такие как семантическое моделирование, аспектно-ориентированный анализ тональности и классификация с использованием предобученных моделей, позволяют трансформировать массивные неструктурированные текстовые корпуса в объективные, количественно измеримые индикаторы. Эта способность извлекать структурированные знания из новостей, отчётов и научных публикаций делает Text Mining незаменимым инструментом для мониторинга социально-экономических и экологических процессов в условиях цифровой эпохи.

Реализация подобных систем сопряжена с рядом методологических вызовов. К ним относятся проблема дисбаланса классов в обучающих данных, необходимость кросс-языковой адаптации и сложность интерпретации результатов, которые могут отражать не объективный прогресс, а специфику политического или медийного дискурса.

На основании изученных подходов можно определить основные математические и методы, которые будут лежать в основе проектируемого приложения. Его архитектура должна включать модуль сбора и предобработки разнородных данных, аналитическое ядро на базе современных языковых моделей (например, BERT или его аналогов), настроенных для решения задач классификации и , а также блок визуализации и интерпретации результатов. Особое внимание следует уделить созданию обучающей и тестовых выборок, необходимых для повышения точности анализа в конкретной предметной области и интерпретации результатов.

Таким образом, рассмотренные подходы предоставляют методический фундамент исследовательской работы. Дальнейший этап исследования заключается в разработке приложения, позволяющего осуществить комплексную оценку показателей устойчивого развития.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1 United Nations. Sustainable Development Goals Knowledge Platform [Electronic resource online]. — [S. l. : s. n.], 2024. — Access mode: https://sdgs.un.org/. Accessed: 2025-01-08.

2 Holden, Erling. Sustainable development: Notions, numbers, and narratives [Text] / Holden, Erling, Linnerud, Kristin, and Bøe, Vegard // Sustainable Development. — 2025. — Vol. 33, no. 2. — P. 2812–2825.

3 Indicator Assessment of Sustainable Development Goals: A Global Perspective [Text] / D'Adamo, I., Della Sciucca, M., Gastaldi, M., and Lupi, B. // Sustainability. — 2025. — Vol. 17, no. 18. — P. 8259.

4 Agbana, Z. E. Assessing the Contribution of the Sustainable Development Goals (SDGs) to Economic Growth and National Development in Nigeria [Text] // International Journal of Research and Scientific Innovation. — 2025. — Vol. 12, no. 3. — P. 45–56.

5 Integrating Sustainable Development Goals into Life Cycle Thinking: A Multidimensional Approach for Advancing Sustainability [Text] / Sala, S., Vasta, A., Mancini, L., and Dewulf, J. // Environment, Development and Sustainability. — 2025. — Vol. 27. — P. 11245–11268.

6 Monitoring of Sustainable Development Trends: Text Mining in Regional Media [Text] / Chernyshova, G., Taran, E., Firsova, A., and Vavilina, A. // Sustainability. — 2025. — Vol. 17, no. 7. — P. 3122.

7 Achieving Sustainable Development Goals through Corporate Sustainability: A Topic Modeling-Based Bibliometric Analysis [Text] / Arora, M., Gupta, J., Mittal, A., and Prakash, A. // Kybernetes. — 2025. — Vol. 54. — P. 3833–3859.

8 NLTK Project. Natural Language Toolkit [Electronic resource online] // [https://www.nltk.org/]. — [S. l. : s. n.], 2023. — Accessed: 2025-12-08.

9 Natural Language Processing and Network Analysis Provide Novel Insights on Policy and Scientific Discourse Around Sustainable Development Goals [Text] / Smith, T. B., Vacca, R., Mantegazza, L., and Capua, I. // Scientific Reports. — 2021. — Vol. 11. — P. 22427.

10 Wijffels, Jan. Doc2Vec Model Documentation [Electronic resource online]. — [S. l. : s. n.], 2025. — Access mode: https://rdrr.io/cran/doc2vec/man/ (online; accessed: 2025-11-08). R package documentation.

11 Кочкаров, А. А. Агрегированный подход выделения сообществ в социальных сетях на основе базовых алгоритмов [Текст] / Кочкаров, А. А., Калашников, Н. В. и Кочкаров, Р. А. // Известия ВУЗов. Серия «Экономика, финансы и управление производством». — 2019. — С. 123–131.

12 Finding Common Development Paths in Voluntary National Reviews Reporting on Sustainable Development Goals Using Aspect-Based Sentiment Analysis [Text] / Funk, C., Tönjes, E., Teuber, R., and Breuer, L. // PLOS ONE. — 2024. — Vol. 19, no. 8. — P. e0307886.

13 Capturing research literature attitude towards Sustainable Development Goals: an LLM-based topic modeling approach [Text] / Invernici, F., Curati, F., Jakimov, J., Samavi, A., and Bernasconi, A. // arXiv preprint. — 2025. — Submitted for publication. 2411.02943.

14 Sufi, Fahim. Mapping the Global Discourse on Sustainable Development: A Sentiment-Based Clustering of SDG Narratives Across 100 Countries [Text] / Sufi, Fahim, Alghamdi, Mohammed J., and Alsulami, Musleh // Sustainability. — 2025. — Vol. 17, no. 16. — P. 7455.

15 Leveraging AI and Data Visualization for Enhanced Policy-Making: Aligning Research Initiatives with Sustainable Development Goals [Text] / Barros, M. H. L. F. d. S., Neto, L. M., Santos, G. L., Leal, R. C. d. S., da Silva, R. C. L., Lynn, T., Dourado, R. A., and Endo, P. T. // Sustainability. — 2024. — Vol. 16. — P. 11050.

16 Mousazadeh, H. Generative Artificial Intelligence for Sustainable Development: Mapping Research Trends and Applications [Text] // SN Applied Sciences. — 2025. — Vol. 7. — P. 7207.

17 Moradi, Z. Comparative Analysis of Sustainable Urban Development Unraveling Challenges and Dimensions in Different Continents and Utilizing AI with BERT Model for Articles Classification [Text] / Moradi, Z., Moradi, M. A., and Ziari, K. // International Review for Spatial Planning and Sustainable Development D: Planning Assessment. — 2025. — Vol. 13, no. 1. — P. 230–256.

18 Guisiano, J. E. SDG-Meter: A deep learning based tool for automatic text classification of the Sustainable Development Goals [Text] / Guisiano, J. E., Chiky, R., and De Mello, J. // Intelligent Information and Database Systems: 14th Asian Conference, ACIIDS 2022, Proceedings, Part I. — [S. l. : s. n.]. — 2022. — P. 259–271.

19 Rostam, Zhyar Rzgar K. Advances in Pre-trained Language Models for Domain-Specific Text Classification: A Systematic Review [Text] / Rostam, Zhyar Rzgar K. and Kertész, Gábor // ACM Transactions on Intelligent Systems and Technology. — 2025. — Vol. 16, no. 6. — P. 1–41.

20 Cojocaru, S. Adapting Tools for Text Monitoring and for Scenario Analysis Related to the Field of Social Disasters [Text] / Cojocaru, S., Petic, M., and Titchiev, I. // International Journal of Computer and Information Engineering. — 2016. — Vol. 10, no. 10. — P. 1790–1796.