МИНОБРНАУКИ РОССИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«САРАТОВСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ИМЕНИ Н. Г. ЧЕРНЫШЕВСКОГО»

Кафедра дискретной математики и информационных технологий

АНАЛИЗ ТОНАЛЬНОСТИ РЕГИОНАЛЬНОЙ НОВОСТНОЙ ПОВЕСТКИ В КОНТЕКСТЕ ЦЕЛЕЙ УСТОЙЧИВОГО РАЗВИТИЯ

КУРСОВАЯ РАБОТА

студента 1 курса 171 группы
направления 09.04.01 — Информатика и вычислительная техника
факультета КНиИТ
Тарана Евгения Вячеславовича

Научный руководитель
доцент, к. э. н. _____ Г. Ю. Чернышова

Заведующий кафедрой
к. ф.-м. н. _____ Л. Б. Тяпаев

Саратов 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ 3
1 Обзор методов классификации текстовых сообщений 5
1.1 Классические методы классификации текстов 5
1.2 Архитектура BERT 6
1.3 RuBERT: русскоязычная модификация BERT 8
1.4 Словарные методы анализа тональности 8
1.5 Группировка целей устойчивого развития в категории 10
2 Классификация текстовых сообщений в соответствии с целями устойчивого развития 12
2.1 Применение BERT-модели для тематической классификации 12
2.2 Применение словарных методов для анализа тональности 13
2.3 Апробация для отдельных регионов 14
2.3.1 Распределение текстов по категориям ЦУР 14
2.3.2 Тональность по категориям ЦУР 16
2.3.3 Межрегиональное сравнение экономической повестки 18
2.3.4 Сопоставление с социально-экономическими показателями регионов 19
2.3.5 Корреляционный анализ (коэффициент Кендалла) 22
2.3.6 Дополнительная проверка на уровне отдельных ЦУР 25
2.3.7 Панельная регрессия с фиксированными эффектами 27
ЗАКЛЮЧЕНИЕ 30
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 33
Приложение А Перечень ключевых слов для отбора сообщений 36
Приложение Б Код извлечения и агрегации показателей Росстата 38
Приложение В Код объединения данных и корреляционного анализа 42

ВВЕДЕНИЕ

В условиях цифровой трансформации общества объёмы текстовых данных, генерируемых в социальных сетях, новостных ресурсах и блогах, растут экспоненциально. Ручной анализ таких данных становится невозможным из-за их масштаба и разнообразия, что делает технологии автоматизированного сбора и анализа текстовой информации критически важными.

Особую актуальность задача автоматического анализа приобретает для русскоязычного контента, где наблюдается дефицит качественных инструментов тематической классификации и оценки тональности, особенно в предметных областях, связанных с целями устойчивого развития (ЦУР). Цели устойчивого развития, принятые ООН в 2015 году, представляют собой систему из 17 взаимосвязанных глобальных задач, охватывающих широкий спектр проблем: от ликвидации нищеты и голода до борьбы с изменением климата и сохранения экосистем. Автоматическое соотнесение новостных сообщений с конкретными ЦУР позволяет оценить, какие аспекты устойчивого развития находятся в фокусе общественного внимания в различных регионах, а анализ тональности этих сообщений даёт возможность интерпретировать эмоциональную окраску общественной реакции.

Интеграция методов обучения для тематической классификации с методами анализа тональности позволяет создать комплексный инструмент оценки общественных настроений в контексте устойчивого развития. Модели на основе архитектуры BERT демонстрируют высокую точность в задачах многоклассовой классификации текстов благодаря способности учитывать двунаправленный контекст слов, в то время как словарные методы анализа тональности не требуют длительного обучения на размеченных данных и обеспечивают прозрачную интерпретацию результатов.

Целью данной курсовой работы является анализ тональности региональной новостной повестки Российской Федерации в контексте целей устойчивого развития и сопоставление полученных текстовых характеристик с социально-экономическими показателями регионов. Для достижения поставленной цели необходимо решить следующие задачи:

— выполнить классификацию собранных текстовых данных по 17 целям устойчивого развития с помощью модели RuBERT;
— провести анализ тональности классифицированных текстов с

использованием словарного метода;

- сопоставить распределение и тональность новостных сообщений по категориям ЦУР в разрезе регионов и лет;
- сопоставить характеристики новостной повестки с официальными социально-экономическими показателями регионов.

1 Обзор методов классификации текстовых сообщений

1.1 Классические методы классификации текстов

Классификация текстов — задача автоматического присвоения категорий текстовым данным, прошла длинный путь развития, отражающий эволюцию технологий обработки естественного языка. Первые подходы к решению этой задачи основывались на ручном создании экспертных правил, таких как поиск ключевых слов или использование регулярных выражений. Однако такие системы были трудоёмкими в поддержке, плохо адаптировались к новым данным и не учитывали контекстную неоднозначность.

С развитием машинного обучения фокус сместился на статистические методы. Тексты стали представляться в виде числовых векторов: модель «мешка слов» (Bag of Words), где учитывалась частота слов, или TF-IDF, где вес слова зависел от его важности в документе и корпусе. Эти представления использовались в сочетании с классическими алгоритмами классификации.

Одним из наиболее интерпретируемых методов является дерево решений (Decision Tree): оно последовательно разделяет данные по значениям признаков, например по наличию отдельных слов или весам TF-IDF, а итоговый класс задаётся листовым узлом. Для повышения устойчивости такого подхода применяется случайный лес (Random Forest) [1], объединяющий множество деревьев, обученных на разных подвыборках данных и признаков. Итоговое решение принимается голосованием деревьев, что снижает риск переобучения и обычно повышает качество классификации по сравнению с одиночным деревом.

Другими распространёнными классическими методами являются метод опорных векторов (SVM) и наивный байесовский классификатор. SVM строит разделяющую гиперплоскость в пространстве признаков, максимизирующую зазор между классами, и эффективен при работе с разреженными данными, характерными для текстовой векторизации TF-IDF. Наивный байесовский классификатор основан на теореме Байеса с предположением о независимости признаков и, несмотря на простоту, показывает приемлемые результаты в задачах бинарной классификации текстов.

Однако все перечисленные классические подходы имеют принципиальные ограничения. Во-первых, представление текста в виде «мешка слов» игнорирует порядок слов и синтаксические связи между ними, что приводит к потере

контекстуальной информации. Во-вторых, классические методы не способны улавливать семантическую близость слов: например, слова «экономика» и «хозяйство» будут рассматриваться как независимые признаки, несмотря на смысловую связь. В-третьих, для достижения высокого качества требуется тщательный ручной отбор признаков (feature engineering) и настройка параметров модели под каждую конкретную предметную область.

Стремление преодолеть указанные ограничения привело к развитию нейросетевых подходов, в частности архитектур глубокого обучения, способных автоматически извлекать иерархические признаки из текста и учитывать контекст.

1.2 Архитектура BERT

Появление распределённых представлений слов (word embeddings), таких как Word2Vec, GloVe и FastText, стало важным шагом вперёд. Эти методы кодировали слова в плотные векторы фиксированной размерности, сохраняющие семантические связи: например, векторное представление слова «король» приближалось к разности векторов «королева» и «женщина». Однако статические эмбеддинги имели ключевой недостаток: они не могли отражать многозначность слов, кодируя слово «ключ» одинаково в контекстах «ключ от двери», «музыкальный ключ» и «криптографический ключ».

Следующим этапом стали рекуррентные нейронные сети (RNN) и их усовершенствованная версия, сети с долгой краткосрочной памятью (LSTM), которые обрабатывали текст как последовательность, учитывая зависимости между словами. Однако эти архитектуры страдали от проблемы «исчезающих градиентов» при работе с длинными текстами и, будучи однонаправленными, учитывали только левый контекст каждого слова.

Радикальное изменение принесла архитектура трансформеров, представленная в 2017 году [2]. Ключевым нововведением стал механизм самовнимания (self-attention), позволяющий каждому токену в последовательности напрямую взаимодействовать с любым другим токеном, независимо от их относительного положения. Технически это реализуется через три обучаемые матрицы: запросов (Q), ключей (K) и значений (V). Веса внимания вычисляются через функцию softmax от скалярных произведений запросов и ключей:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (1)$$

где d_k — размерность векторов ключей.

Модель BERT (Bidirectional Encoder Representations from Transformers) [3], ~~разработанная Google в 2018 году~~, использует исключительно кодирующую часть трансформера и достигает ~~прорывных~~ результатов благодаря двунаправленному анализу контекста. В отличие от предшествующих моделей, где контекст накапливался только слева направо, BERT одновременно учитывает как предшествующий, так и последующий контекст каждого слова, что критически важно для разрешения лексической многозначности.

Каждый слой кодировщика BERT состоит из блока multi-head attention и полносвязной прямой сети (feed-forward network). Multi-head attention позволяет нескольким модулям внимания работать параллельно, изучая различные типы зависимостей в тексте: синтаксические, семантические, лексические. Выходы модулей конкатенируются и проецируются в исходную размерность. После каждой операции применяются остаточные связи (residual connections) и нормализация слоя (layer normalization), обеспечивающие стабильность обучения глубоких сетей.

Предобучение BERT осуществляется на двух задачах. Первая — Masked Language Modeling (MLM), где 15% случайных токенов в тексте заменяются маской [MASK], а модель обучается их восстанавливать по контексту. Вторая — Next Sentence Prediction (NSP), где модель определяет, действительно ли одно предложение следует за другим в оригинальном тексте. Этот двухэтапный процесс позволяет BERT освоить как лексико-семантические, так и дискурсивные закономерности языка.

Для задач классификации используется выходное представление специального токена [CLS], добавляемого в начало каждой последовательности. Считается, что этот вектор агрегирует информацию обо всём документе, и к нему добавляется классификатор, обычно один или несколько полносвязных слоёв, дообучаемых на целевом наборе данных.

Ключевым преимуществом BERT является возможность дообучения (fine-tuning): модель, предобученная на больших корпусах текстов (Wikipedia, новостные статьи), может быть быстро адаптирована к узкоспециализированной задаче даже при ограниченном размере размеченной выборки. Это существенно

сокращает затраты на разметку данных и делает технологию доступной для научных и прикладных проектов.

1.3 RuBERT: русскоязычная модификация BERT

Для обработки русскоязычных текстов особый интерес представляет модель RuBERT (DeepPavlov/rubert-base-cased) [4], специализированная версия BERT, дообученная на обширных корпусах русскоязычных текстов, включая новостные статьи, материалы Wikipedia и данные социальных медиа. RuBERT наследует архитектуру оригинального BERT (178 миллионов параметров, 12 слоёв кодировщика) и использует токенизацию WordPiece, адаптированную для морфологически сложного русского языка.

В сравнительных экспериментах по классификации текстов по целям устойчивого развития [5] модель RuBERT показала наилучшие результаты среди трёх протестированных архитектур — Multilingual BERT [3], RuBERT [4] и XLM-RoBERTa [6] — достигнув F1-меры 0.884 на объединённой обучающей выборке, что превосходит показатели Multilingual BERT (F1=0.878) и XLM-RoBERTa (F1=0.850). Архитектура модели включает дополнительный классификатор: промежуточный полносвязный слой с 256 нейронами и функцией активации ReLU, слой регуляризации Dropout с вероятностью 0.3 и выходной слой с 17 нейронами и активацией softmax, соответствующий числу классов ЦУР. Сходная логика автоматического сопоставления текстов с ЦУР используется в открытом подходе OSDG [7], инструменте SDG-Meter [8] и системах поддержки принятия решений, совмещающих AI-классификацию с визуальной аналитикой [9].

1.4 Словарные методы анализа тональности

Анализ тональности текстов (Sentiment Analysis) представляет собой процесс автоматического определения эмоциональной окраски текстовых данных. В области компьютерной лингвистики анализ тональности традиционно реализуется через два принципиально различных подхода: классические алгоритмы машинного обучения, требующие размеченных обучающих выборок, и словарные методы, опирающиеся на заранее составленные лексиконы тональности. Словарный подход обладает рядом преимуществ: он не требует размеченной обучающей выборки, обеспечивает прозрачную интерпретацию результатов и легко адаптируется к различным предметным

областям путём дополнения словаря доменно-специфичными терминами.

Словарный метод основан на использовании специализированных лингвистических ресурсов: словарей, в которых каждому слову или выражению сопоставлена оценка тональности. Для анализа русскоязычных текстов в данной работе используется словарь КартаСловСент (kartaslovsent) [10]. Выбор данного словаря обоснован следующими соображениями:

— Объём словаря. КартаСловСент содержит около 46 тысяч терминов, что почти втрое превышает объём наиболее известного русскоязычного аналога RuSentiLex [11] (16 тыс. записей). Больший объём словаря критически важен для анализа региональных новостных сообщений, лексика которых может существенно выходить за пределы ядра общеупотребительных оценочных слов.

— Дробная шкала тональности. Каждой лексической единице сопоставлено дробное значение тональности в диапазоне от -1 до 1 (например, 0.08 для нейтрально-позитивных слов и -0.68 для явно негативных). Дробная шкала позволяет более гибко учитывать неоднозначность эмоциональной окраски слов, в отличие от дискретной трёхклассовой схемы (позитив / нейтрально / негатив), характерной для RuSentiLex. Это особенно важно при анализе новостных текстов, где оценочность часто выражена неявно.

— Дополнительные метрики. Словарь содержит долю разметчиков, отнёсших слово к позитивному, негативному и нейтральному классам, что позволяет при необходимости учитывать согласованность экспертных оценок.

— Актуальность. Словарь опубликован в 2021 году и отражает современное состояние русской оценочной лексики, включая лексику социальных медиа.

Алгоритм словарного анализа тональности включает следующие этапы. На первом этапе производится предварительная обработка текста: удаление пунктуации, специальных символов и стоп-слов (часто встречающихся слов, не несущих смысловой нагрузки). На втором этапе текст разбивается на отдельные слова, каждое из которых подвергается лемматизации (приведению к нормальной форме) с помощью морфологического анализатора (в реализации используется библиотека pymorphy3). Лемматизация критически важна для русского языка с его развитой морфологией, так как позволяет сопоставить словарной записи любую словоформу (например,

«экономический», «экономического», «экономическому» будут приведены к лемме «экономический» для поиска в словаре). На третьем этапе для каждого слова осуществляется поиск в словаре тональности: если лемма найдена, соответствующее значение тональности добавляется к суммарной оценке текста. Итоговая тональность текста определяется как среднее арифметическое значений всех найденных в словаре слов. Текст классифицируется как позитивный, если средняя оценка превышает пороговое значение 0.2; в противном случае — как негативный.

Преимуществом словарного подхода является отсутствие необходимости в размеченной обучающей выборке и высокая интерпретируемость результатов: всегда можно проследить, какие именно слова определили итоговую оценку тональности. Кроме того, словарный метод легко адаптируется к различным предметным областям путём дополнения словаря доменно-специфичными терминами.

1.5 Группировка целей устойчивого развития в категории

Принятые ООН 17 целей устойчивого развития охватывают три ключевых измерения устойчивого развития [12]: социальное развитие, экономическое развитие и экологическую устойчивость. Такое укрупнение позволяет рассматривать не только отдельные цели, но и более общие направления региональной повестки.

- социальное измерение связано с качеством жизни, доступом к базовым услугам, здоровьем, образованием, безопасностью и снижением социального неравенства;
- экономическое измерение отражает занятость, рост, инфраструктуру, инновации, производство и развитие партнёрств;
- экологическое измерение охватывает климатическую повестку, состояние природных ресурсов и сохранение экосистем.

В рамках данной работы для анализа региональной повестки используется ~~расширенная~~ группировка всех 17 целей в три категории:

- Социальные: ЦУР 1 (ликвидация нищеты), 2 (ликвидация голода), 3 (здоровье), 4 (образование), 5 (гендерное равенство), 6 (чистая вода и санитария), 7 (доступная энергия), 11 (устойчивые города), 16 (мир и правосудие);
- Экономические: ЦУР 8 (экономический рост и занятость), 9

(инфраструктура и инновации), 10 (сокращение неравенства), 12 (ответственное потребление и производство), 17 (партнёрство в интересах устойчивого развития);

— Экологические: ЦУР 13 (борьба с изменением климата), 14 (сохранение морских экосистем), 15 (сохранение экосистем суши).

Данная категоризация позволяет агрегировать результаты классификации на более высоком уровне и сопоставлять распределение общественного внимания по трём макронаправлениям устойчивого развития ~~в различных регионах Российской Федерации~~.

В исследованиях устойчивого развития текстовая тональность SDG-сообщений может рассматриваться как самостоятельный нарративный индикатор, дополняющий официальные статистические показатели. Такой подход используется в работе [13], где тональность текстов, связанных с целями устойчивого развития, сопоставляется с внешними показателями прогресса по ЦУР. В данной работе эта логика применяется к региональной новостной повестке: анализируется не только тематическое распределение сообщений по категориям ЦУР, но и эмоциональная окраска этих сообщений. В современной литературе новостной дискурс всё чаще рассматривается как самостоятельный источник информации о приоритетах устойчивого развития: региональные медиа используются для мониторинга тенденций устойчивого развития [14], тексты международных документов анализируются методами NLP и сетевого анализа [15], а тематическое моделирование применяется для изучения научного и корпоративного SDG-дискурса [16, 17]. Это подтверждается и недавним масштабным исследованием [18], где на материале 135 тыс. новостных сообщений из 100 стран показано, что структура и тональность SDG-нарративов соотносятся с уровнем человеческого развития, экономическими характеристиками и параметрами медиа-среды.

2 Классификация текстовых сообщений в соответствии с целями устойчивого развития

2.1 Применение BERT-модели для тематической классификации

Для классификации текстовых данных по целям устойчивого развития использована модель RuBERT [4], дообученная на корпусе SDG-размеченных текстов [5]. Модель построена на архитектуре DeepPavlov/rubert-base-cased с добавлением классификатора: промежуточный полносвязный слой (256 нейронов, функция активации ReLU), слой регуляризации Dropout (вероятность 0.3) и выходной слой с 17 нейронами и функцией активации softmax. Обучение проводилось на объединённой выборке из двух корпусов: OSDG Community Dataset и SDGi Corpus, общим объёмом около 27 000 текстов после предобработки, с использованием оптимизатора Adam (learning rate = 2×10^{-5}, batch size = 16) в течение 6 эпох. Модель достигла F1-меры 0.884 на тестовой выборке, что является лучшим результатом среди рассмотренных архитектур [5]. Дополнительно тестовая выборка из социальной сети «ВКонтакте» была собрана по тем же ключевым словам и размечена вручную для проверки применимости модели к региональным новостным сообщениям; она не использовалась для полноценной переоценки качества модели.

Исходные текстовые данные собраны из региональных новостных сообществ социальной сети «ВКонтакте» с использованием API VK. Сбор производился по трём субъектам Российской Федерации: Астраханской области, Омской области и Республике Татарстан. Для каждого региона извлекались посты из релевантных региональных новостных сообществ за заданный временной интервал. Для фильтрации сообщений применялся механизм поиска по ключевым словам: текст каждого поста проверялся на соответствие регулярному выражению, построенному на основе заданного набора ключевых слов с применением стемминга (выделения основы слова) для обеспечения морфологической вариативности поиска.

Полный перечень ключевых слов приведён в приложении А. Ключевые слова были сгруппированы по тематическим блокам, соответствующим целям устойчивого развития, и использовались как фильтр для отбора релевантных сообщений из региональных новостных сообществ.

Данные охватывают три региона Российской Федерации за период 2020–2025 годов и включают 9 765 текстовых сообщений, распределённых по 18

файлам. Характеристика исходного набора представлена в таблице 1.

Таблица 1 – Характеристика исходного набора данных

Регион	2020	2021	2022	2023	2024	2025
Астраханская область	945	716	953	903	523	683
Омская область	323	238	350	329	358	337
Татарстан	262	741	595	516	369	624

Каждый текст был подан на вход модели RuBERT, которая сформировала для него предсказание класса ЦУР в формате «SDG N» (где N — номер цели от 1 до 17) и значение уверенности (confidence) в интервале от 0 до 1. Для последующего анализа использовались предсказания с уверенностью не ниже порогового значения 0.85. Данный порог выбран как компромисс между сохранением достаточного объёма выборки и повышением надёжности автоматической разметки: менее уверенные предсказания исключались из дальнейшей агрегации.

2.2 Применение словарных методов для анализа тональности

Для оценки тональности классифицированных текстов применён словарный метод с использованием лексикона КартаСловСент [10]. ~~Выбор данного словаря обоснован в разделе 1.4: дробная шкала тональности и большой объём (около 46 тыс. терминов) обеспечивают более точную оценку оценочной лексики региональных новостных сообщений.~~

Алгоритм обработки для каждого файла включал следующие шаги. На первом этапе производилась загрузка SDG-размеченных данных (столбцы «text», «predicted_class», «confidence») с фильтрацией по порогу уверенности 0.85. На втором этапе каждому тексту сопоставлялась одна из трёх категорий ЦУР (социальные, экономические, экологические) в соответствии с классификацией, описанной в разделе 1.5. На третьем этапе текст подвергался лемматизации с помощью морфологического анализатора pymorphy3: для каждого слова определялась его нормальная форма, после чего из текста удалялись стоп-слова. На четвёртом этапе для каждой леммы выполнялся поиск в словаре КартаСловСент, и на основе найденных оценок вычислялась средняя тональность текста. Текст классифицировался как позитивный, если средняя оценка превышала порог 0.2; в противном случае — как негативный.

Результаты обработки агрегировались по следующим разрезам: регион, год, категория ЦУР (социальные / экономические / экологические). Для каждой комбинации фиксировалось общее количество текстов, количество текстов с найденной тональностью и доля позитивных текстов.

2.3 Апробация для отдельных регионов

Обработка 9 765 текстов позволила получить детальную картину распределения общественного внимания по категориям целей устойчивого развития и его эмоциональной окраски для трёх регионов России.

2.3.1 Распределение текстов по категориям ЦУР

Результаты группировки предсказаний модели RuBERT по трём категориям ЦУР представлены в таблице 2. Во всех трёх регионах доминирует социальная повестка, составляющая в среднем 74.5% от общего числа сообщений. Наибольшая доля социальных ЦУР зафиксирована в Астраханской области (в среднем 84.0%), наименьшая — в Татарстане (68.3%). Экономическая категория в среднем составляет 15.4%, однако её доля заметно варьируется: в Омской области она достигает 22.8% (с пиком 45.7% в 2025 году), тогда как в Астраханской области — лишь 7.2%. Экологическая повестка наиболее выражена в Татарстане (15.3%) и наименее — в Омской области (6.1%).

Таблица 2 – Среднее распределение текстов по категориям ЦУР (2020–2025)

Регион	Всего текстов	Социальные, %	Экономические, %	Экологические, %
Астраханская область	4 723	84.0	7.2	8.9
Омская область	1 935	71.2	22.8	6.1
Татарстан	3 107	68.3	16.4	15.3
Все регионы	9 765	74.5	15.4	10.1

На рисунке 1 представлено распределение текстов Астраханской области по категориям ЦУР в динамике по годам. Аналогичные диаграммы для Омской области и Татарстана приведены на рисунках 2 и 3 соответственно.

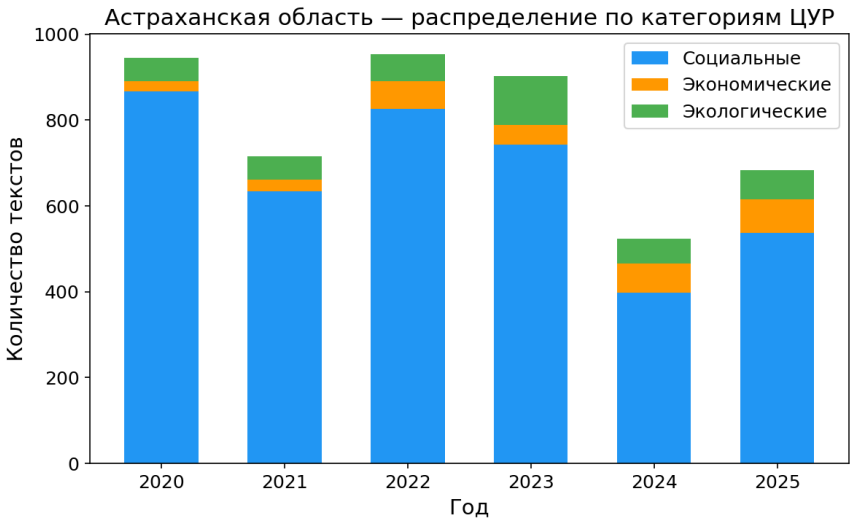


Рисунок 1 – Распределение текстов по категориям ЦУР, Астраханская область

Диаграмма демонстрирует устойчивое доминирование социальной повестки в Астраханской области на протяжении всего периода наблюдения: её доля последовательно снижается с 91.6% в 2020 году до 82.3% в 2023 году, однако остаётся выше 80%. Экономическая повестка представлена минимально: от 2.6% до 6.8%, что указывает на слабое присутствие экономической тематики в региональном новостном поле. Экологическая повестка показывает заметный рост в 2023 году (до 12.6%), что может быть связано с конкретными региональными событиями (например, обсуждение состояния Волги или Каспийского моря).

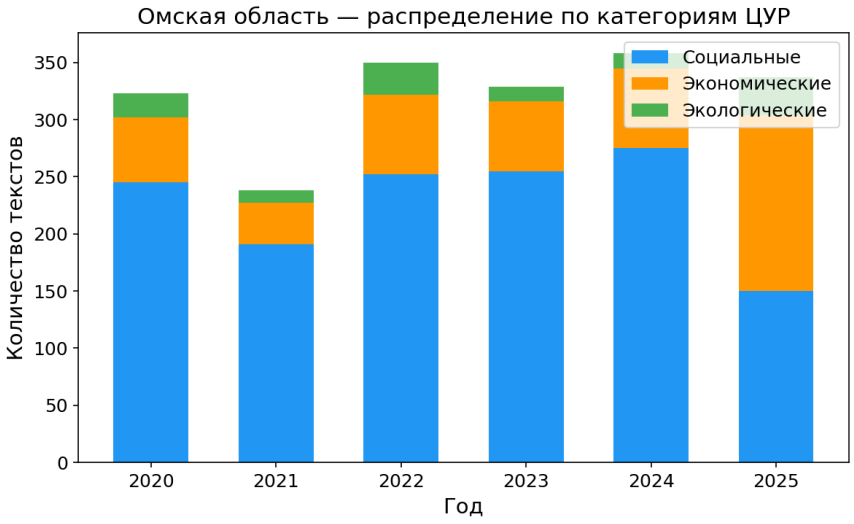


Рисунок 2 – Распределение текстов по категориям ЦУР, Омская область

Диаграмма для Омской области показывает более сбалансированное

распределение категорий по сравнению с Астраханской областью. Доля экономической повестки стабильно находится на уровне 15–20%, а в 2025 году достигает пика в 45.7%, что связано с активным обсуждением крупных инфраструктурных проектов в регионе. Социальная повестка, оставаясь доминирующей, снижается с 80% в 2021 году до 72% в 2022 году. Экологическая категория занимает наименьшую долю среди трёх регионов — 4–8%.

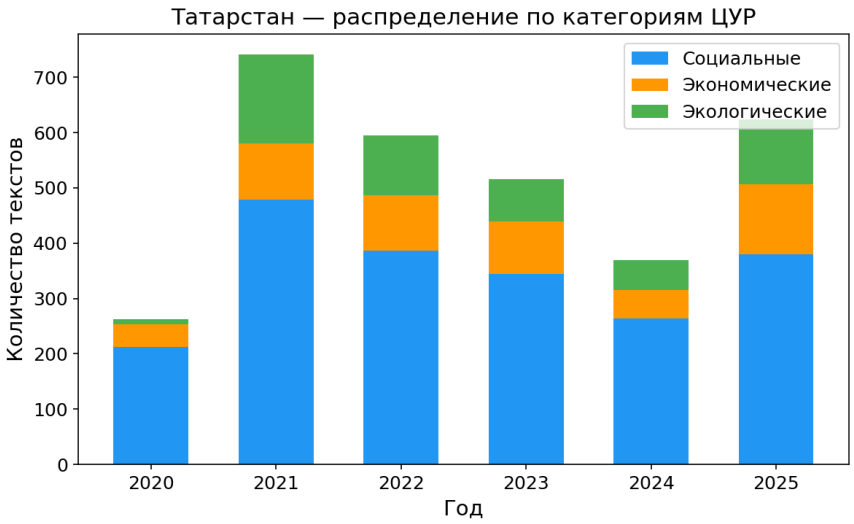


Рисунок 3 – Распределение текстов по категориям ЦУР, Татарстан

Диаграмма для Татарстана демонстрирует наиболее выраженную экологическую повестку среди трёх регионов (до 21.7% в 2021 году), а также заметный спад социальной доли с 81.3% в 2020 году до 64.6% в 2021 году с последующей стабилизацией на уровне 65–67%. Экономическая повестка плавно растёт с 13.6% в 2021 году до 18.4% в 2023 году, что отражает повышенное внимание к вопросам промышленного развития и инноваций, характерное для региона с развитой нефтехимической и машиностроительной отраслями.

2.3.2 Тональность по категориям ЦУР

Результаты анализа тональности с использованием словаря КартаСловСент представлены в таблице 3. Экономическая категория демонстрирует наиболее высокую долю позитивных текстов во всех трёх регионах: от 88.7% в Татарстане до 92.7% в Омской области. Социальная повестка характеризуется умеренно-позитивной тональностью (от 74.1% в

Татарстане до 85.1% в Омской области). Экологическая категория, напротив, показывает наименьшую долю позитива: от 46.6% в Татарстане до 75.2% в Астраханской области.

Таблица 3 – Средняя доля позитивных текстов по категориям ЦУР и регионам (2020–2025, КартаСловСент)

Регион	Социальные, %	Экономические, %	Экологические, %
Астраханская область	78.9	91.4	75.2
Омская область	85.1	92.7	59.4
Татарстан	74.1	88.7	46.6

Результаты, полученные с использованием словаря КартаСловСент (таблица 3), показывают устойчивый межкатегориальный градиент позитивности, сохраняющийся во всех трёх регионах.

На рисунке 4 показана динамика тональности по категориям ЦУР для Астраханской области. Экономическая повестка на протяжении всего периода сохраняет высокий уровень позитивности (в среднем выше 90%), в то время как социальная и экологическая категории демонстрируют более выраженные колебания.

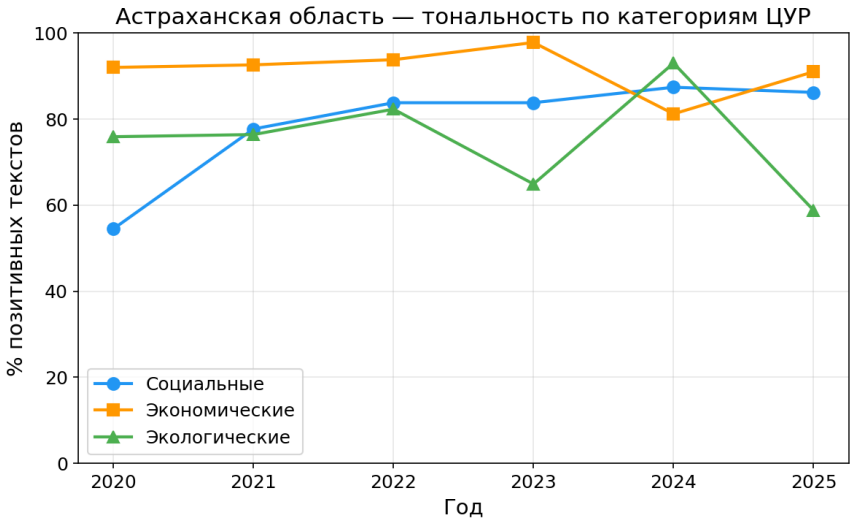


Рисунок 4 – Динамика тональности по категориям ЦУР, Астраханская область (КартаСловСент)

Диаграмма отражает три важные закономерности. Во-первых, экономическая позитивность стабильно находится на уровне выше 90% и практически не подвержена годовым колебаниям, что говорит о

последовательно конструктивном характере экономических новостей. Во-вторых, социальная позитивность демонстрирует выраженный восходящий тренд с 54.5% в 2020 году до 83.8% в 2022–2023 годах, что может быть связано с постепенным смещением социальной повестки от кризисных тем (пандемия COVID-19) к темам развития и восстановления. В-третьих, экологическая позитивность подвержена наибольшим колебаниям (от 64.9% до 82.3%), что отражает нестабильный характер экологической повестки, зависящей от конкретных информационных поводов.

2.3.3 Межрегиональное сравнение экономической повестки

Особый интерес представляет сопоставление тональности экономической повестки между регионами (рисунок 5). По данным словаря КартаСловСент, все три региона демонстрируют стабильно высокую позитивность экономических сообщений на уровне 85–95%. Омская область лидирует по данному показателю (92.7%), за ней следуют Астраханская область (91.4%) и Татарстан (88.7%). Высокая позитивность экономической повестки может объясняться преобладанием в новостных сообщениях материалов о развитии инфраструктуры, инвестиционных проектах и мерах государственной поддержки, которые, как правило, подаются в позитивном ключе.

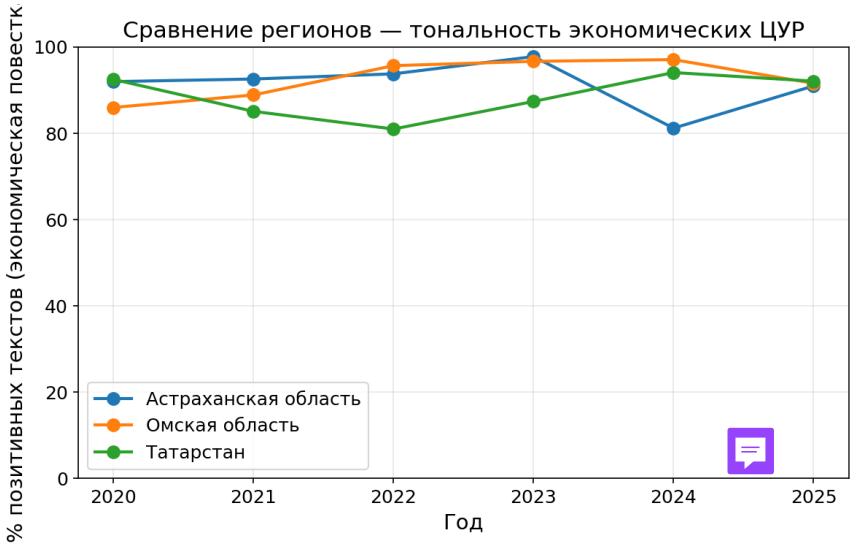


Рисунок 5 – Сравнение тональности экономической повестки по регионам (КартаСловСент)

Диаграмма показывает, что, несмотря на существенные различия в уровне экономического развития регионов (ВРП на душу населения в

Татарстане в 2–3 раза выше, чем в Астраханской и Омской областях), уровень позитивности экономической повестки не демонстрирует соответствующей дифференциации. Более того, наименее экономически развитая Омская область лидирует по позитивности экономических сообщений, а наиболее развитый Татарстан показывает наименьший уровень. Данное наблюдение служит эмпирическим основанием для осторожной гипотезы о том, что тональность региональной новостной повестки в социальных медиа может быть связана не только с объективным экономическим положением, но и с характером информационного освещения.

2.3.4 Сопоставление с социально-экономическими показателями регионов

Методологически данный этап близок к подходу [13], где текстовая тональность сообщений, связанных с целями устойчивого развития, сопоставляется с официальными показателями прогресса по ЦУР. Выбранная логика сопоставления текстовых характеристик с внешними социально-экономическими показателями соответствует и более широкому направлению исследований, представленному, в частности, работой [18], где агрегированные характеристики новостного SDG-дискурса сопоставляются с макроуровневыми индикаторами стран. В обеих указанных работах объектами анализа выступают страны, тогда как в данной работе аналогичная логика применяется на региональном уровне: единицей наблюдения является пара «регион — год», а источником текстовой информации служат новостные сообщения социальной сети «ВКонтакте». Объединение результатов тематической классификации, словарного анализа тональности и статистических показателей, а также расчёт корреляций и панельных регрессий выполнялись скриптом, приведённым в приложении В.

По аналогии с модульной схемой анализа новостного SDG-дискурса, предложенной в работе [18], общую структуру данного исследования можно представить как последовательное преобразование неструктурированных текстов в агрегированные региональные индикаторы повестки, а затем в сопоставимые статистические признаки. Схематическое изображение этапов исследования приведено на рисунке 6.



Рисунок 6 – Этапы ~~обработки и~~ анализа региональной новостной повестки в контексте ЦУР

Схема показывает последовательность этапов исследования: от классификации исходных сообщений до расчёта агрегированных текстовых характеристик и их сопоставления с показателями Росстата.

Для проверки гипотезы о связи тональности новостной повестки с объективным социально-экономическим положением регионов проведено сопоставление результатов анализа с официальными статистическими данными Росстата [19] за 2020–2023 годы. При интерпретации таких сопоставлений важно учитывать, что оценки прогресса по ЦУР и устойчивого развития зависят от выбранного набора индикаторов, способа их нормализации и агрегирования [20]. Из ежегодного статистического сборника «Регионы России. Социально-экономические показатели» [19] для каждого региона извлечены 15 показателей, сгруппированных по трём тематическим направлениям, соответствующим категориям ЦУР:

— социальные: уровень безработицы, коэффициент рождаемости, смертность на 100 тыс. населения, обеспеченность врачами и больничными койками на 10 тыс. населения;
— экономические: ВРП на душу населения, инвестиции в основной капитал на душу населения, среднемесячная номинальная заработная плата, оборот розничной торговли на душу населения;
— экологические: выбросы загрязняющих веществ в атмосферу, доля уловленных и обезвреженных веществ, забор свежей воды, сброс загрязнённых сточных вод, расходы на охрану окружающей среды на душу населения.

Данные извлекались из статистических сборников за 2021, 2022, 2023, 2024 и 2025 годы (разделы 2, 3, 4, 6, 8, 9, 10, 16) с использованием скрипта, приведённого в приложении Б. При наличии значений в нескольких публикациях использовалась наиболее поздняя доступная редакция. Ключевые показатели за все годы приведены в таблице 4.

Таблица 4 – Ключевые социально-экономические показатели регионов по данным Росстата (2020–2023)

Регион	Год	ВРП на душу, руб.	Безработица, %	Инвестиции на душу, руб.	Средняя зарплата, руб.	Выбросы, тыс. т
Астраханская обл.	2020	541 099	7.9	115 116	38 885	112
	2021	688 988	7.8	115 484	42 096	91
	2022	800 576	7.1	87 352	47 780	104
	2023	819 952	4.4	89 373	53 964	100
Омская обл.	2020	407 371	8.9	200 450	37 828	147
	2021	426 872	6.5	191 473	41 152	159
	2022	503 176	5.3	194 431	46 952	165
	2023	578 934	3.6	208 399	55 227	159
Респ. Татарстан	2020	658 312	3.6	615 593	39 761	325
	2021	883 564	2.7	689 232	45 800	323
	2022	1 035 953	2.3	888 649	52 274	320
	2023	1 145 174	2.1	1 180 448	61 894	320

Для сопоставления в таблице 5 приведены соответствующие характеристики новостной повестки за те же периоды: доли каждой из трёх категорий ЦУР в общем объёме сообщений и доля позитивных текстов по данным словаря КартаСловСент.

Таблица 5 – Характеристики новостной повестки по категориям ЦУР (2020–2023, КартаСловСент)

Регион	Год	Соц., %	Экон., %	Экол., %	+Соц, %	+Экон, %	+Экол, %
Астраханская обл.	2020	91.6	2.6	5.7	54.5	92.0	75.9
	2021	88.5	3.8	7.7	77.7	92.6	76.4
	2022	86.7	6.8	6.5	83.8	93.8	82.3
	2023	82.3	5.1	12.6	83.8	97.8	64.9
Омская обл.	2020	75.9	17.6	6.5	83.7	86.0	38.1
	2021	80.3	15.1	4.6	84.8	88.9	18.2
	2022	72.0	20.0	8.0	88.1	95.7	92.9
	2023	77.5	18.5	4.0	92.5	96.7	100
Респ. Татарстан	2020	81.3	15.3	3.4	83.6	92.5	100
	2021	64.6	13.6	21.7	61.0	85.1	29.7
	2022	65.0	16.8	18.2	65.1	81.0	33.3
	2023	66.7	18.4	14.9	70.3	87.4	40.8

2.3.5 Корреляционный анализ (коэффициент Кендалла)

Сформированный набор данных имеет панельную структуру: одни и те же регионы наблюдаются в течение нескольких лет, поэтому отдельные наблюдения не являются полностью независимыми. Поскольку выборка мала ($n = 12$), а распределения показателей Росстата заведомо отличаются от нормальных (три региона находятся на разных уровнях экономического развития), применение параметрического коэффициента Пирсона не вполне обосновано. В качестве основной меры связи используется непараметрический коэффициент ранговой корреляции Кендалла τ, который, в отличие от коэффициента Спирмена, даёт более консервативную оценку и лучше работает при малом числе наблюдений [13]. Такой выбор соответствует логике сопоставления текстовой тональности с официальными показателями: тональные оценки ограничены диапазоном, а связь между медиаповесткой и статистическими индикаторами может быть монотонной, но не обязательно линейной.

Коэффициент τ вычислялся с использованием реализации scipy.stats.kendalltau (вариант τ_b с поправкой на связанные ранги). Расчёт основан на попарном сравнении всех наблюдений: конкордантные пары дают положительный вклад, если порядок значений x совпадает с порядком значений y, а дискордантные пары дают отрицательный вклад, если эти порядки противоположны. Вариант τ_b дополнительно корректирует значение

коэффициента при наличии связанных рангов, то есть совпадающих значений в одном или обоих сравниваемых рядах.

Корреляционный анализ проводился попарно между двумя наборами переменных. Первый набор — 6 характеристик новостной повестки (доли социальной, экономической и экологической категорий в общем объёме сообщений, а также доли позитивных текстов в каждой из трёх категорий). Второй набор — 14 показателей Росстата, сгруппированных по трём направлениям: социальные (уровень безработицы, коэффициент рождаемости, смертность на 100 тыс. населения, обеспеченность врачами и больничными койками на 10 тыс. населения), экономические (ВРП на душу населения, инвестиции на душу населения, среднемесячная номинальная заработная плата, оборот розничной торговли на душу населения) и экологические (выбросы загрязняющих веществ в атмосферу, доля уловленных и обезвреженных веществ, забор свежей воды, сброс загрязнённых сточных вод, расходы на охрану окружающей среды на душу населения). Каждая пара «характеристика повестки — показатель Росстата» образует набор из $n = 12$ наблюдений (3 региона $\times$ 4 года, 2020–2023). Для каждого такого набора оба ряда значений преобразуются в ранги.

Ранг $R(x_i)$ величины x_i в выборке объёмом n — это её порядковый номер в отсортированном по возрастанию ряду $\{x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)}\}$. Например, для ряда значений ВРП на душу: 407 371, 541 099, 658 312 ранги равны соответственно 1, 2, 3 (наименьшее значение получает ранг 1). При совпадении значений (связанные ранги) каждому из совпавших наблюдений присваивается среднее арифметическое их потенциальных номеров. Переход от абсолютных значений к рангам делает анализ нечувствительным к форме распределения данных и к наличию выбросов, что критически важно при малой выборке.

Коэффициент τ принимает значения от -1 (полная противоположность ранговых порядков) до $+1$ (полное совпадение), ноль означает отсутствие монотонной связи. Величина p (p-value) — это вероятность получить наблюдаемое значение $|\tau|$ или ещё более экстремальное при условии, что в действительности между переменными нет никакой связи (нулевая гипотеза). Вычисление p основано на асимптотической нормальности статистики Кендалла: при $n \geq 10$ стандартизованное значение $z = \tau / SE(\tau)$, где $SE(\tau)$ —

стандартная ошибка τ, учитывающая объём выборки и количество связанных рангов, распределено приближённо нормально. Величина p вычисляется как $P(|Z| \geq |z|)$ для стандартного нормального распределения. Чем меньше p, тем менее вероятно, что обнаруженная корреляция случайна: $p < 0.05$ считается статистически значимым, $p < 0.01$ — высоко значимым.

Результаты корреляционного анализа для 6 характеристик новостной повестки и 14 показателей Росстата представлены в таблице 6. Полная матрица содержит $6 \times 14 = 84$ пары; для компактности и содержательной интерпретации в таблицу включены только пары, для которых $|\tau| > 0.40$ (умеренная или сильная монотонная связь). Порог 0.40 является общепринятой границей умеренной непараметрической корреляции; пары с $|\tau| \leq 0.40$ при $n = 12$ соответствуют слабым ассоциациям, не поддающимся содержательной интерпретации. Из 84 пар данному критерию удовлетворяют 15.

Таблица 6 – Коэффициент корреляции Кендалла (τ) между показателями Росстата и характеристиками новостной повестки (2020–2023, ~~$n = 12$~~). Показаны пары с $|\tau| > 0.40$

Характеристика повестки	Показатель Росстата	τ	p
Доля соц. кат., %	Обеспеченность врачами на 10 тыс.	0.76	0.001
Доля экон. кат., %	Коэффициент рождаемости	-0.72	0.001
Доля соц. кат., %	Обеспеченность койками на 10 тыс.	0.70	0.002
Доля соц. кат., %	Сброс загрязнённых сточных вод	-0.68	0.002
Доля соц. кат., %	Расходы на охрану среды на душу	-0.64	0.003
Доля экон. кат., %	Расходы на охрану среды на душу	0.64	0.003
Доля соц. кат., %	Выбросы в атмосферу	-0.59	0.009
Доля соц. кат., %	Инвестиции на душу	-0.58	0.009
Доля соц. кат., %	Оборот розницы на душу	-0.55	0.014
Доля соц. кат., %	Уровень безработицы	0.53	0.016
Позитивность соц., %	Коэффициент рождаемости	-0.52	0.019
Доля экон. кат., %	Доля уловленных загрязнителей	0.50	0.023
Позитивность экон., %	Инвестиции на душу	-0.46	0.045
Позитивность экон., %	Обеспеченность врачами на 10 тыс.	0.45	0.045
Доля экол. кат., %	ВРП на душу	0.44	0.046

Результаты корреляционного анализа указывают на то, что структурные

характеристики новостной повестки (доли категорий) в рассматриваемой выборке чаще образуют более выраженные ассоциации с показателями Росстата, чем показатели тональности. Доля социальной повестки положительно коррелирует с обеспеченностью врачами ($\tau = 0.76$, $p = 0.001$) и больничными койками ($\tau = 0.70$, $p = 0.002$), а также с уровнем безработицы ($\tau = 0.53$, $p = 0.016$). Одновременно она отрицательно связана с инвестициями на душу населения ($\tau = -0.58$, $p = 0.009$), выбросами ($\tau = -0.59$, $p = 0.009$) и расходами на охрану среды ($\tau = -0.64$, $p = 0.003$). Эти результаты не следует трактовать как доказательство причинной зависимости; они скорее показывают, что в данной выборке структура региональной повестки может соотноситься с отдельными социально-экономическими характеристиками регионов.

Для показателей тональности обнаруженные ассоциации слабее и менее устойчивы. Экономическая позитивность имеет умеренную отрицательную корреляцию с инвестициями на душу населения ($\tau = -0.46$, $p = 0.045$) и не показывает значимой связи с ВРП на душу населения ($\tau = -0.03$, $p = 0.913$). Социальная позитивность отрицательно связана с коэффициентом рождаемости ($\tau = -0.52$, $p = 0.019$), однако при малом числе наблюдений такую связь следует рассматривать только как предварительное наблюдение, требующее проверки на расширенной выборке.

2.3.6 Дополнительная проверка на уровне отдельных ЦУР

Поскольку агрегация 17 целей устойчивого развития в три категории может сглаживать различия между отдельными целями, была выполнена дополнительная поисковая проверка для нескольких ЦУР, наиболее близких по смыслу к доступным показателям Росстата. Для каждой пары «регион — год — ЦУР» была рассчитана доля позитивных текстов по словарю КартаСловСент. Далее эти значения сопоставлялись с тематически близкими статистическими показателями: для ЦУР 3 — с медицинскими индикаторами, для ЦУР 8 и ЦУР 9 — с экономическими показателями, для ЦУР 11 — с показателями социальной и городской инфраструктуры, для ЦУР 13 и ЦУР 15 — с экологическими индикаторами.

С учётом малого числа наблюдений результаты данного расчёта имеют вспомогательный характер. Для снижения влияния единичных сообщений использовался фильтр: в расчёт включались только наблюдения,

где по соответствующей ЦУР было не менее 10 текстов в регионе и году. Пары, где после фильтрации оставалось менее 6 наблюдений, не интерпретировались. Следует также учитывать, что расчёт включает несколько парных сопоставлений, поэтому полученные значения используются как ориентир для поиска возможных направлений дальнейшего анализа. В таблице 7 приведены только наиболее содержательные результаты дополнительной проверки.

Таблица 7 – ~~Дополнительная проверка~~ корреляции Кендалла между тональностью отдельных ЦУР и показателями Росстата (2020–2023)

ЦУР	Показатель Росстата	τ	p	n
ЦУР 8	ВРП на душу населения	0.473	0.033	12
ЦУР 8	Среднемесячная заработная плата	0.473	0.033	12
ЦУР 8	Инвестиции на душу населения	0.351	0.114	12
ЦУР 9	Инвестиции на душу населения	-0.545	0.025	11
ЦУР 13	Выбросы загрязняющих веществ	-0.473	0.105	8

Результаты дополнительной проверки позволяют отметить, что на уровне отдельных целей могут проявляться связи, которые слабее видны при анализе укрупнённых категорий. Наиболее заметные ассоциации получены для ЦУР 8: позитивность сообщений о достойной работе и экономическом росте положительно связана с ВРП на душу населения и среднемесячной заработной платой ($\tau = 0.473$, $p = 0.033$). Это наблюдение можно рассматривать как указание на то, что именно более узкая экономическая цель лучше соотносится с экономическими показателями региона, чем вся экономическая категория в целом.

Для ЦУР 9 получена отрицательная корреляция с инвестициями на душу населения ($\tau = -0.545$, $p = 0.025$, $n = 11$). Данный результат не следует трактовать как свидетельство негативного влияния инвестиций на медиаповестку. Более вероятно, что сообщения об инфраструктуре, промышленности и инвестиционных проектах в регионах с высокой инвестиционной активностью чаще связаны не только с достижениями, но и с проблемами реализации, сроками, строительными работами и общественным обсуждением. Для ЦУР 13 после фильтрации наблюдается умеренная отрицательная связь с выбросами ($\tau = -0.473$, $p = 0.105$), однако из-за малого числа наблюдений ($n = 8$) этот результат можно рассматривать только как направление для дальнейшей проверки.

Таким образом, дополнительный расчёт не меняет основной вывод работы, но уточняет его. При текущем объёме данных анализ трёх укрупнённых категорий остаётся более устойчивым, однако переход к отдельным ЦУР может дать более содержательную интерпретацию для тех целей, по которым накоплено достаточно текстов. В дальнейшем такой подход целесообразно применять на расширенной выборке регионов и лет.

2.3.7 Панельная регрессия с фиксированными эффектами

Для проверки устойчивости корреляционных выводов и частичного учёта панельной структуры данных дополнительно проведён регрессионный анализ с фиксированными эффектами по регионам. Выбор модели с фиксированными эффектами (FE) обусловлен тремя соображениями. Во-первых, простая объединённая регрессия (pooled OLS) смешала бы межрегиональные различия с внутрирегиональной динамикой: тот факт, что Татарстан всегда богаче и при этом имеет иную структуру новостной повестки, не говорит о влиянии ВРП на тональность — он лишь отражает устойчивые различия между регионами. FE-модель, вводя индивидуальные свободные члены α_i, отделяет эти постоянные региональные особенности от эффекта изменения переменной x_{it} во времени внутри одного региона. Во-вторых, модель со случайными эффектами (RE) требует допущения о некоррелированности региональных особенностей α_i с регрессорами; в данном случае это допущение является сомнительным, поскольку уровень экономического развития тесно связан с принадлежностью к конкретному региону. В-третьих, при $N = 3$ невозможно провести тест Хаусмана для формального выбора между FE и RE, поскольку асимптотические свойства теста не выполняются на столь малой выборке. Модель специфицирована как:

$$y_{it} = \alpha_i + \beta \cdot x_{it} + \varepsilon_{it}, \tag{2}$$

где y_{it} — характеристика новостной повестки для региона i в году t, x_{it} — показатель Росстата, α_i — фиксированный эффект региона (дамми-переменная), β — оцениваемый коэффициент, ε_{it} — случайная ошибка. Оценивание выполнено методом наименьших квадратов с использованием библиотеки statsmodels (класс OLS).

В таблице регрессий величина p используется как ориентир для оценки

того, насколько надёжно коэффициент β отличается от нуля. Нулевая гипотеза в данном случае означает, что после учёта устойчивых различий между регионами показатель Росстата не связан с рассматриваемой характеристикой новостной повестки. Если оценённый коэффициент велик по сравнению с разбросом данных вокруг регрессионной линии, значение p получается малым; если же коэффициент сопоставим со случайными колебаниями, p остаётся большим. Поэтому малые значения p указывают на более заметную статистическую ассоциацию, а большие значения p — на отсутствие убедительных оснований считать связь устойчивой. При этом из-за малого числа наблюдений ($n = 12$) и всего трёх регионов приводимые p-значения следует рассматривать только как ориентировочные, а не как строгое доказательство наличия или отсутствия зависимости.

Результаты для восьми пар «характеристика повестки — показатель Росстата» представлены в таблице 8. В связи с малым объёмом выборки ($n = 12$, $T = 4$, $N = 3$) и, как следствие, низкой статистической мощностью, результаты следует интерпретировать как предварительные.

Таблица 8 – Результаты панельной регрессии с фиксированными эффектами по регионам (2020–2023, $n = 12$)

Зависимая переменная	Независимая переменная	β	p
Доля экол. кат., %	ВРП на душу	$1.3 \cdot 10^{-5}$	0.090
Доля экон. кат., %	Инвестиции на душу	$1.4 \cdot 10^{-5}$	0.135
Доля соц. кат., %	Уровень безработицы	1.35	0.248
Позитивность экол., %	Выбросы в атмосферу	1.64	0.297
Позитивность соц., %	Уровень безработицы	-2.02	0.355
Позитивность соц., %	ВРП на душу	$1.1 \cdot 10^{-5}$	0.631
Позитивность экон., %	Инвестиции на душу	$-7.7 \cdot 10^{-7}$	0.580
Позитивность экон., %	ВРП на душу	$3.4 \cdot 10^{-8}$	0.986

Результаты панельной регрессии не противоречат наблюдениям корреляционного анализа, однако также должны интерпретироваться как предварительные. Ни одна из моделей, где зависимой переменной выступает позитивность (социальная, экономическая или экологическая), не демонстрирует статистически значимого коэффициента при соответствующем показателе Росстата ($p > 0.1$ для всех пар). Единственная пара с

коэффициентом, значимым на 10-процентном уровне, связь доли экологической повестки с ВРП на душу населения ($\beta = 1.3 \cdot 10^{-5}$, $p = 0.090$), согласуется с положительной корреляцией Кендалла ($\tau = 0.44$, $p = 0.046$), но не позволяет делать строгий вывод о направлении или механизме связи.

Дополнительно была проверена регрессионная спецификация с min-max-нормировкой зависимых и независимых переменных в диапазон от 0 до 1. Такая нормировка изменяет масштаб коэффициентов, но не меняет значения p и R^2, поэтому содержательный вывод остаётся тем же: наиболее заметной остаётся связь доли экологической повестки с ВРП на душу населения, тогда как модели для показателей позитивности не дают убедительных оснований говорить об устойчивой зависимости.

Полученные результаты в целом согласуются с современными исследованиями медиадискурса устойчивого развития. Как показано в работе [18], структура новостного SDG-дискурса и его тональность могут быть связаны не только с самими целями устойчивого развития, но и с социально-экономическим и институциональным контекстом. В нашем случае это проявляется в том, что структурные характеристики региональной повестки (доли категорий) образуют более заметные ассоциации с показателями Росстата, чем показатели позитивности, которые могут в большей степени зависеть от редакционной политики и информационной повестки конкретных сообществ.

Таким образом, совокупность результатов корреляционного и регрессионного анализа позволяет сформулировать осторожный вывод: сопоставление медиадискурса с официальной статистикой может использоваться для поиска возможных взаимосвязей между структурой региональной повестки и социально-экономическим положением регионов. При этом тональность региональной новостной повестки не следует напрямую отождествлять с объективным состоянием экономики, экологии или социальной сферы: она может отражать не только реальные процессы, но и особенности информационного отбора, редакционной подачи и текущих новостных поводов. Данный вывод согласуется с результатами исследования [13], показавшего, что тональность текстовых SDG-нарративов в большинстве случаев не имеет прямой статистически значимой связи с официальными показателями прогресса по целям устойчивого развития.

ЗАКЛЮЧЕНИЕ

В результате выполнения курсовой работы решена задача анализа тональности региональной новостной повестки в контексте целей устойчивого развития. Были собраны и обработаны 9 765 текстовых сообщений из региональных новостных сообществ социальной сети «ВКонтакте» по трём субъектам Российской Федерации: Астраханской области, Омской области и Республике Татарстан за период 2020–2025 годов.

Для тематической классификации сообщений использована модель RuBERT [4], дообученная на корпусе SDG-размеченных текстов [5]. Каждое сообщение было отнесено к одной из 17 целей устойчивого развития, после чего цели были агрегированы в три укрупнённые категории: социальную, экономическую и экологическую. Это позволило перейти от анализа отдельных классов ЦУР к сопоставлению макронаправлений региональной повестки.

Проведённый анализ показал, что во всех трёх регионах доминирует социальная повестка: в среднем она составляет 74.5% сообщений. Экономическая категория занимает меньшую долю информационного поля (15.4%), однако характеризуется наиболее высокой позитивностью. Экологическая категория, напротив, демонстрирует наименьшую долю позитивных сообщений, особенно в Республике Татарстан.

Для оценки тональности классифицированных текстов использован словарь КартаСловСент [10], один из крупнейших русскоязычных тональных словарей (46 тыс. терминов) с дробной шкалой оценки. Выбор словаря обоснован его объёмом, детальностью разметки и актуальностью.

Выполнено сопоставление характеристик новостной повестки с 15 социально-экономическими показателями Росстата [19] за 2020–2023 годы. Сформированный набор данных имеет панельную структуру ($N = 3$, $T = 4$, $n = 12$). С использованием коэффициента Кендалла и панельной регрессии с фиксированными эффектами по регионам показано, что тональность (позитивность) новостной повестки в данной выборке не обнаруживает устойчивой статистически значимой связи с ключевыми экономическими показателями, включая ВРП на душу населения. В то же время структурные характеристики повестки (распределение долей категорий) образуют более заметные ассоциации с социально-экономическими индикаторами. Дополнительная проверка на уровне отдельных целей позволяет

предположить, что для некоторых тематически близких пар, прежде всего для ЦУР 8 и экономических показателей, могут проявляться более выраженные ассоциации, чем при анализе укрупнённых категорий. Эти результаты следует рассматривать не как окончательное доказательство зависимости, а как основание для дальнейшей проверки гипотезы о связи между медиадискурсом и социально-экономическим контекстом регионов.

Таким образом, проведённая работа показывает, что объединение тематической SDG-классификации, словарного анализа тональности и официальной статистики может быть перспективным способом выявления возможных взаимосвязей между медиадискурсом и положением дел в социальной, экономической и экологической сферах. Однако такие взаимосвязи требуют осторожной интерпретации: медиаповестка не является прямым отражением реальности, а формируется под влиянием новостных поводов, редакционного отбора, локального контекста и особенностей платформы.

Основным ограничением выполненного анализа является малый размер выборки: рассматриваются только три региона и четыре года, что не позволяет делать строгие выводы о характере и направлении выявленных ассоциаций. Кроме того, в работе не учитывались временные лаги между освещением события в медиапространстве и его возможным отражением в официальной статистике. Новостные сообщения могут предшествовать изменениям в экономике, экологии или социальной жизни, а могут, наоборот, реагировать на уже произошедшие процессы; при этом годовые показатели Росстата фиксируют агрегированный результат с задержкой. Поэтому связь между медиадискурсом и реальными изменениями может проявляться не синхронно, а через один или несколько последующих периодов.

Перспективными направлениями дальнейшего исследования являются расширение выборки на большее число субъектов Российской Федерации, увеличение временного горизонта, применение лаговых спецификаций, сопоставляющих медиапоказатели за год t с социально-экономическими показателями последующих лет, использование аспектно-ориентированного анализа тональности и сопоставление текстовых индикаторов с более широким набором социально-экономических показателей. Отдельным направлением может стать переход от трёх укрупнённых категорий к анализу отдельных ЦУР при условии накопления достаточного числа текстов по каждой цели.

При таких доработках предложенный подход может стать более надёжным инструментом для анализа взаимосвязи между региональным медиадискурсом и реальными социально-экономическими процессами.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1 Breiman, L. Random Forests [Text] // Machine Learning. — 2001. — Vol. 45, no. 1. — P. 5–32.

2 Attention Is All You Need [Text] / Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. // Advances in Neural Information Processing Systems. — 2017. — Vol. 30. — P. 5998–6008. — URL: https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.

3 BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding [Text] / Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. // Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT). — 2019. — P. 4171–4186. — URL: https://aclanthology.org/N19-1423/.

4 Kuratov, Y. Adaptation of Deep Bidirectional Multilingual Transformers for Russian Language [Text] / Kuratov, Y. and Arkhipov, M. // arXiv preprint arXiv:1905.07213. — 2019. — URL: https://arxiv.org/abs/1905.07213.

5 Морозов, Н. А. Разработка приложения для классификации новостных статей с помощью BERT-моделей (бакалаврская работа) [Текст]. — Саратов : Саратовский национальный исследовательский государственный университет имени Н. Г. Чернышевского, 2025.

6 Unsupervised Cross-lingual Representation Learning at Scale [Text] / Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., and Stoyanov, V. // Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL). — 2020. — P. 8440–8451. — URL: https://aclanthology.org/2020.acl-main.747/.

7 OSDG — Open-Source Approach to Classify Text Data by UN Sustainable Development Goals (SDGs) [Text] / Pukelis, L., Bautista-Puig, N., Statulevičius, G., Stančiauskas, V., Dikmener, G., and Akyürek, D. // arXiv preprint arXiv:2008.11333. — 2020.

8 Guisiano, J. E. SDG-Meter: A deep learning based tool for automatic text classification of the Sustainable Development Goals [Text] / Guisiano, J. E., Chiky, R., and De Mello, J. // Intelligent Information and Database Systems: 14th Asian Conference, ACIIDS 2022, Proceedings, Part I. — [S. l. : s. n.]. — 2022. — P. 259–271.

9 Leveraging AI and Data Visualization for Enhanced Policy-Making: Aligning Research Initiatives with Sustainable Development Goals [Text] / Barros, M. H. L. F. d. S., Neto, L. M., Santos, G. L., Leal, R. C. d. S., da Silva, R. C. L., Lynn, T., Dourado, R. A., and Endo, P. T. // Sustainability. — 2024. — Vol. 16. — P. 11050.

10 Кулагин, Д. И. Открытый тональный словарь русского языка КартаСловСент [Текст] // Компьютерная лингвистика и интеллектуальные технологии: по материалам ежегодной Международной конференции «Диалог». Вып. 20. — 2021. — С. 1106–1119. — URL: http://www.dialog-21.ru/media/5570/kulagindi026.pdf.

11 Loukachevitch, N. Creating a General Russian Sentiment Lexicon [Text] / Loukachevitch, N. and Levchik, A. // Proceedings of the Tenth International Conference on Language Resources and Evaluation (LREC 2016). — 2016. — P. 1171–1176. — URL: http://www.lrec-conf.org/proceedings/lrec2016/pdf/285_Paper.pdf.

12 Генеральная Ассамблея ООН. Преобразование нашего мира: Повестка дня в области устойчивого развития на период до 2030 года [Электронный ресурс онлайн] : Организация Объединённых Наций. — [Б. м. : б. и.], 2015. — URL: https://undocs.org/ru/A/RES/70/1 (дата обращения: 07.06.2026).

13 Finding common development paths in voluntary national reviews reporting on sustainable development goals using aspect-based sentiment analysis [Text] / Funk, C., Tönjes, E., Teuber, R., and Breuer, L. // PLOS ONE. — 2024. — Vol. 19, no. 8. — P. e0307886.

14 Monitoring of Sustainable Development Trends: Text Mining in Regional Media [Text] / Chernyshova, G., Taran, E., Firsova, A., and Vavilina, A. // Sustainability. — 2025. — Vol. 17, no. 7. — P. 3122.

15 Natural Language Processing and Network Analysis Provide Novel Insights on Policy and Scientific Discourse Around Sustainable Development Goals [Text] /

Smith, T. B., Vacca, R., Mantegazza, L., and Capua, I. // Scientific Reports. — 2021. — Vol. 11. — P. 22427.

16 Achieving Sustainable Development Goals through Corporate Sustainability: A Topic Modeling-Based Bibliometric Analysis [Text] / Arora, M., Gupta, J., Mittal, A., and Prakash, A. // Kybernetes. — 2025. — Vol. 54. — P. 3833–3859.

17 Capturing research literature attitude towards Sustainable Development Goals: An LLM-based topic modeling approach [Text] / Invernici, F., Curati, F., Jakimov, J., Samavi, A., and Bernasconi, A. // arXiv preprint arXiv:2411.02943. — 2025. — URL: https://arxiv.org/abs/2411.02943.

18 Sufi, F. Mapping the Global Discourse on Sustainable Development: A Sentiment-Based Clustering of SDG Narratives Across 100 Countries [Text] / Sufi, F., Alghamdi, M. J., and Alsulami, M. // Sustainability. — 2025. — Vol. 17, no. 16. — P. 7455.

19 Росстат. Регионы России. Социально-экономические показатели: электронные версии статистического сборника [Электронный ресурс онлайн] : Федеральная служба государственной статистики. — [Б. м. : б. и.], 2024. — URL: https://rosstat.gov.ru/folder/210/document/13204 (дата обращения: 07.06.2026).

20 Indicator Assessment of Sustainable Development Goals: A Global Perspective [Text] / D'Adamo, I., Della Sciucca, M., Gastaldi, M., and Lupi, B. // Sustainability. — 2025. — Vol. 17, no. 18. — P. 8259.

ПРИЛОЖЕНИЕ А

Перечень ключевых слов для отбора сообщений

Для отбора релевантных сообщений использовались следующие тематические группы ключевых слов:

- ЦУР 1: бедность, распределение доходов, доходы населения, благосостояние, социальная безопасность;
- ЦУР 2: продовольственная безопасность, продовольственный суверенитет, культура питания, регенеративное сельское хозяйство, органическая еда, цена на продукты питания;
- ЦУР 3: психическое здоровье, общественное здравоохранение, психическое благополучие, инвалидность, санитарное просвещение, инфекционные заболевания, детская смертность, планирование семьи, неонатальная смертность, младенческая смертность, здоровье детей, дорожно-транспортные происшествия, репродуктивное здоровье, эпидемии, медицинское страхование;
- ЦУР 4: образование, экологическое образование, профессиональное техническое обучение, бесплатное образование, доступное образование, начальное образование, среднее образование, высшее образование;
- ЦУР 5: гендерное равенство;
- ЦУР 6: рекультивация, эффективность использования воды, истощение грунтовых вод, опустынивание, зелёная инфраструктура;
- ЦУР 7: возобновляемая энергия, ветровая, солнечная, геотермальная, гидроэлектрическая энергия, топливосберегающие технологии, выбросы, парниковый эффект, биотопливо;
- ЦУР 8: занятость, экономический рост, устойчивое развитие, заработная плата, расширение экономических прав и возможностей, малые и средние предприятия, занятость молодёжи;
- ЦУР 9: инфраструктура, инвестиции, интернет, промышленная диверсификация;
- ЦУР 10: торговля, финансовый рынок, налогообложение, социальное обеспечение, государственная программа;
- ЦУР 11: общественный транспорт, адаптация к изменению климата, доступное жильё, пешеходная зона, общественные пространства;
- ЦУР 12: природные ресурсы, переработка, промышленная экология,

повторное использование, декарбонизация, пищевые отходы;

— ЦУР 13: климат, парниковый газ, глобальное потепление, погода, окружающая среда;
— ЦУР 14: защита водных ресурсов, рыбные запасы;
— ЦУР 15: землепользование, экологическое восстановление земель, сохранение лесов, вырубка лесов, лесовозобновление;
— ЦУР 16: социальная справедливость, правовая система, борьба с терроризмом.

ПРИЛОЖЕНИЕ Б

Код извлечения и агрегации показателей Росстата

В листинге приведён скрипт, использованный для извлечения показателей из статистических сборников Росстата и формирования агрегированного файла `region_indicators.csv`.

```
# coding: utf-8
"""Extract Rosstat regional indicators from .docx and .xlsx files into CSV."""
import os
import pandas as pd
from docx import Document

REGIONS_MAP = {
    'Астраханская область': 'Астраханская область',
    'Астраханская об': 'Астраханская область',
    'Омская область': 'Омская область',
    'Омская об': 'Омская область',
    'Республика Татарстан': 'Татарстан',
    'Респ Татарстан': 'Татарстан',
    'Республика Татарстан (Татарстан)': 'Татарстан',
}

DATA_DIR = 'data/region_stats'

def parse_number(value_str):
    value_str = str(value_str).replace(',', '.').replace(' ', '').replace('\xa0', '').replace('\u2009', '')
    try:
        return float(value_str)
    except ValueError:
        return None

def extract_docx_table(doc, table_indices, year_cols):
    results = {}
    for ti in table_indices:
        if ti >= len(doc.tables):
            continue
        t = doc.tables[ti]
        for row in t.rows:
            cells = [c.text.strip() for c in row.cells]
            if not cells:
                continue
            for rn, mapping in REGIONS_MAP.items():
                if rn in cells[0]:
                    values = {}
                    for year, col in year_cols.items():
                        if col < len(cells):
                            val = parse_number(cells[col])
                            if val is not None:
                                values[year] = val
                    if values:
                        results[mapping] = values
                    break
    return results

def extract_xlsx_table(filepath, year_cols):
    """Extract from individual xlsx file (2022 publication format)."""
    results = {}
```

```
    df = pd.read_excel(filepath, engine='openpyxl')
    for _, row in df.iterrows():
        region_cell = str(row.iloc[0])
        for rn, mapping in REGIONS_MAP.items():
            if rn in region_cell:
                values = {}
                for year, col in year_cols.items():
                    if col < len(row):
                        val = parse_number(row.iloc[col])
                        if val is not None:
                            values[year] = val
                if values:
                    results[mapping] = values
                break
    return results

def main():
    all_records = []

    # === DOCX publications ===
    # Structure: {publication_year: {indicator: (filename, [table_indices], {year: col})}}
    docx_specs = {
        2021: {
            'unemployment_pct': ('R_03.docx', [36, 49], {2020: 3}),
        },
        2023: {
            'grp_per_capita':            ('R_09.docx',  [3, 4],   {2020: 3, 2021: 4, 2022: 5}),
            'unemployment_pct':          ('R_03.docx',  [36, 37], {2021: 1, 2022: 2}),
            'investment_per_capita':     ('R_10.docx',  [1, 2],   {2020: 3, 2021: 4, 2022: 5}),
            'emissions_thousand_tons':   ('R_08.docx',  [7, 8],   {2020: 3, 2021: 4, 2022: 5}),
            'population':                ('R_02.docx',  [0, 1, 3],{2020: 3, 2021: 4, 2022: 5}),
            'birth_rate':                ('R_02.docx',  [22, 23], {2020: 3, 2021: 4, 2022: 5}),
            'deaths_per_100k':           ('R_02.docx',  [26, 27], {2020: 3, 2021: 4, 2022: 5}),
            'doctors_per_10k':           ('R_06.docx',  [6, 7],   {2020: 9, 2021: 10, 2022: 11}),
            'hospital_beds_per_10k':     ('R_06.docx',  [0, 1],   {2020: 9, 2021: 10, 2022: 11}),
            'captured_pollutants_pct':   ('R_08.docx',  [11, 12], {2020: 3, 2021: 4, 2022: 5}),
            'fresh_water_use':           ('R_08.docx',  [13, 14], {2020: 3, 2021: 4, 2022: 5}),
            'polluted_wastewater':       ('R_08.docx',  [17, 18], {2020: 3, 2021: 4, 2022: 5}),
            'environmental_spending':    ('R_08.docx',  [19, 20], {2020: 3, 2021: 4, 2022: 5}),
            'retail_trade':              ('R_16.docx',  [0, 1],   {2020: 3, 2021: 4, 2022: 5}),
            'average_monthly_wage':      ('R_04-1.docx', [10, 11],{2020: 3, 2021: 4, 2022: 5}),
        },
        2024: {
            'grp_per_capita':            ('R_09.docx',  [3, 4],   {2020: 3, 2021: 4, 2022: 5}),
            'unemployment_pct':          ('R_03.docx',  [36, 37], {2021: 1, 2022: 2, 2023: 3}),
            'investment_per_capita':     ('R_10.docx',  [1, 2],   {2020: 3, 2021: 4, 2022: 5}),
            'emissions_thousand_tons':   ('R_08.docx',  [7, 8],   {2020: 3, 2021: 4, 2022: 5}),
            'population':                ('R_02.docx',  [0, 1, 3],{2020: 3, 2021: 4, 2022: 5, 2023: 6}),
            'birth_rate':                ('R_02.docx',  [22, 23], {2020: 3, 2021: 4, 2022: 5, 2023: 6}),
            'deaths_per_100k':           ('R_02.docx',  [26, 27], {2020: 3, 2021: 4, 2022: 5, 2023: 6}),
            'doctors_per_10k':           ('R_06.docx',  [6, 7],   {2020: 9, 2021: 10, 2022: 11, 2023: 13}),
            'hospital_beds_per_10k':     ('R_06.docx',  [0, 1],   {2020: 9, 2021: 10, 2022: 11, 2023: 13}),
            'captured_pollutants_pct':   ('R_08.docx',  [11, 12], {2020: 3, 2021: 4, 2022: 5, 2023: 6}),
            'fresh_water_use':           ('R_08.docx',  [13, 14], {2020: 3, 2021: 4, 2022: 5, 2023: 6}),
            'polluted_wastewater':       ('R_08.docx',  [17, 18], {2020: 3, 2021: 4, 2022: 5, 2023: 6}),
            'environmental_spending':    ('R_08.docx',  [19, 20], {2020: 3, 2021: 4, 2022: 5, 2023: 6}),
            'retail_trade':              ('R_16.docx',  [0, 1],   {2020: 3, 2021: 4, 2022: 5, 2023: 6}),
            'average_monthly_wage':      ('R_04-1.docx', [10, 11],{2020: 3, 2021: 4, 2022: 5, 2023: 6}),
        },
        2025: {
            'grp_per_capita':            ('R_09.docx',  [3, 4],   {2022: 4, 2023: 5}),
```

```
            'unemployment_pct':          ('R_03.docx',  [36, 37], {2023: 2, 2024: 3}),
            'investment_per_capita':     ('R_10.docx',  [1, 2],   {2022: 4, 2023: 5}),
            'emissions_thousand_tons':   ('R_08.docx',  [7, 8],   {2022: 4, 2023: 5}),
            'population':                ('R_02.docx',  [0, 1, 3],{2022: 4, 2023: 5}),
            'birth_rate':                ('R_02.docx',  [22, 23], {2022: 4, 2023: 5}),
            'deaths_per_100k':           ('R_02.docx',  [26, 27], {2022: 4, 2023: 5}),
            'doctors_per_10k':           ('R_06.docx',  [6, 7],   {2022: 9, 2023: 12}),
            'hospital_beds_per_10k':     ('R_06.docx',  [0, 1],   {2022: 9, 2023: 11}),
            'captured_pollutants_pct':   ('R_08.docx',  [11, 12], {2022: 4, 2023: 5}),
            'fresh_water_use':           ('R_08.docx',  [13, 14], {2022: 4, 2023: 5}),
            'polluted_wastewater':       ('R_08.docx',  [17, 18], {2022: 4, 2023: 5}),
            'environmental_spending':    ('R_08.docx',  [19, 20], {2022: 4, 2023: 5}),
            'retail_trade':              ('R_16.docx',  [0, 1],   {2022: 4, 2023: 5}),
            'average_monthly_wage':      ('R_04-1.docx', [10, 11],{2022: 4, 2023: 5}),
        },
    }

    for pub_label, indicators in docx_specs.items():
        pub_path = os.path.join(DATA_DIR, f'Region_Pokaz_{pub_label}')
        if not os.path.isdir(pub_path):
            continue
        for indicator, (fname, table_idx, year_cols) in indicators.items():
            doc_path = os.path.join(pub_path, fname)
            if not os.path.exists(doc_path):
                continue
            doc = Document(doc_path)
            data = extract_docx_table(doc, table_idx, year_cols)
            for region, values in data.items():
                for year, value in values.items():
                    all_records.append({
                        'publication_year': pub_label,
                        'region': region,
                        'year': int(year),
                        'indicator': indicator,
                        'value': value,
                        'unit': '',
                    })

    # === XLSX publication (2022) ===
    xlsx_base = os.path.join(DATA_DIR, 'Region_Pokaz_2022')
    xlsx_specs = {
        'grp_per_capita':            ('09/RR_pokaz_09-02_2022.xlsx', {2020: 5}),
        'investment_per_capita':     ('10/RR_pokaz_10-02_2022.xlsx', {2020: 5, 2021: 6}),
        'emissions_thousand_tons':   ('08/RR_pokaz_08-03_2022.xlsx', {2020: 5, 2021: 6}),
        'population':                ('02/RR_pokaz_02-01_2022.xlsx', {2020: 5, 2021: 6}),
        'doctors_per_10k':           ('06/RR_pokaz_06-03_2022.xlsx', {2020: 11, 2021: 12}),
        'captured_pollutants_pct':   ('08/RR_pokaz_08-05_2022.xlsx', {2020: 5, 2021: 6}),
        'fresh_water_use':           ('08/RR_pokaz_08-06_2022.xlsx', {2020: 5, 2021: 6}),
        'polluted_wastewater':       ('08/RR_pokaz_08-08_2022.xlsx', {2020: 5, 2021: 6}),
        'environmental_spending':    ('08/RR_pokaz_08-09_2022.xlsx', {2020: 4, 2021: 5}),
        'retail_trade':              ('16/RR_pokaz_16-01_2022.xlsx', {2020: 5, 2021: 6}),
    }
    for indicator, (fname, year_cols) in xlsx_specs.items():
        fpath = os.path.join(xlsx_base, fname)
        if not os.path.exists(fpath):
            continue
        data = extract_xlsx_table(fpath, year_cols)
        for region, values in data.items():
            for year, value in values.items():
                all_records.append({
                    'publication_year': 2022,
```

```
                    'region': region,
                    'year': int(year),
                    'indicator': indicator,
                    'value': value,
                    'unit': '',
                })

    if not all_records:
        print('Не удалось извлечь данные.')
        return

    df = pd.DataFrame(all_records)
    # Keep latest publication for each (region, year, indicator)
    df = df.sort_values('publication_year').groupby(
        ['region', 'year', 'indicator'], as_index=False
    ).last()

    df_wide = df.pivot_table(
        index=['region', 'year'],
        columns='indicator',
        values='value'
    ).reset_index()
    df_wide = df_wide.sort_values(['region', 'year'])

    output_path = os.path.join(DATA_DIR, 'region_indicators.csv')
    df_wide.to_csv(output_path, index=False, float_format='%.1f')
    print(f'Сохранено: {output_path}')
    print(f'Регионов: {df_wide["region"].nunique()}, лет: {sorted(df_wide["year"].unique())}')
    print(f'Показателей: {len([c for c in df_wide.columns if c not in ("region","year")])}')
    print()
    print(df_wide.to_string(index=False))

if __name__ == '__main__':
    main()
```

ПРИЛОЖЕНИЕ В

Код объединения данных и корреляционного анализа

В листинге приведён скрипт, использованный для объединения результатов SDG-классификации, словарного анализа тональности и социально-экономических показателей, а также для расчёта коэффициентов Пирсона, Спирмена и Кендалла.

```
# coding: utf-8
"""Merge Rosstat indicators with SDG analysis results. Kendall tau correlations + panel FE regression."""
import os
import pandas as pd
import numpy as np
from scipy.stats import kendalltau
import statsmodels.api as sm
import matplotlib
matplotlib.use('Agg')
import matplotlib.pyplot as plt

ROSTAT_PATH = 'data/region_stats/region_indicators.csv'
SDG_DIST_PATH = 'data/sdg_category_analysis/sdg_category_distribution_20260524_190250.xlsx'
SDG_SENT_PATH = 'data/sdg_sentiment_analysis/sdg_sentiment_by_category_20260524_214856.xlsx'
OUTPUT_DIR = 'data/correlation_analysis'

def panel_fe_regression(data, y_col, x_col):
    """Entity fixed-effects panel regression: y_it = alpha_i + beta * x_it + eps_it.
    Returns (coef, p_value, r2_within, n_obs)."""
    df = data[['region', 'year', y_col, x_col]].dropna().copy()
    if len(df) < 6:
        return None
    # Entity dummies
    dummies = pd.get_dummies(df['region'], drop_first=True, dtype=float)
    X = pd.concat([df[[x_col]], dummies], axis=1)
    X = sm.add_constant(X, has_constant='add')
    y = df[y_col]
    try:
        model = sm.OLS(y, X).fit()
        coef = model.params[x_col]
        pval = model.pvalues[x_col]
        r2 = model.rsquared
        return (coef, pval, r2, len(df))
    except Exception:
        return None

def main():
    os.makedirs(OUTPUT_DIR, exist_ok=True)

    rostat = pd.read_csv(ROSTAT_PATH)
    sdg_dist = pd.read_excel(SDG_DIST_PATH)
    sdg_sent = pd.read_excel(SDG_SENT_PATH)

    # --- Compute per-capita indicators ---
    rostat['retail_trade_per_capita'] = rostat['retail_trade'] * 1e6 / (rostat['population'] * 1e3)
    rostat['environmental_spending_per_capita'] = rostat['environmental_spending'] * 1e6 / (rostat['population'] * 1e3)

    # --- Merge: Rosstat + distribution ---
    dist_cols = ['region', 'year', 'Социальные_pct', 'Экономические_pct', 'Экологические_pct', 'total']
    merged_dist = sdg_dist[dist_cols].merge(rostat, on=['region', 'year'], how='inner')
```

```
51
52      # --- Merge: Rosstat + sentiment (kartaslovsent) ---
53      sent_k = sdg_sent[sdg_sent['dictionary'] == 'kartaslovsent'].pivot_table(
54          index=['region', 'year'], columns='category', values='positive_pct'
55      ).reset_index()
56      sent_k = sent_k.rename(columns={
57          'Социальные': 'pos_social',
58          'Экономические': 'pos_economic',
59          'Экологические': 'pos_environmental',
60      })
61      merged_sent = sent_k.merge(rostat, on=['region', 'year'], how='inner')
62
63      # --- Merge all ---
64      merged = merged_dist.merge(
65          merged_sent[['region', 'year', 'pos_social', 'pos_economic', 'pos_environmental']],
66          on=['region', 'year'], how='inner'
67      )
68      merged = merged[(merged['year'] >= 2020) & (merged['year'] <= 2023)]
69      merged.to_csv(os.path.join(OUTPUT_DIR, 'merged_data.csv'), index=False, float_format='%.2f')
70      print('Объединённые данные (12 строк, 2020-2023):')
71      print(merged[['region', 'year', 'pos_economic', 'grp_per_capita', 'unemployment_pct']].to_string(index=False))
72
73      # === Kendall tau correlations ===
74      rostat_indicators = [
75          # Social
76          ('unemployment_pct',              'Уровень безработицы, %'),
77          ('birth_rate',                    'Коэффициент рождаемости'),
78          ('deaths_per_100k',              'Смертность на 100 тыс.'),
79          ('doctors_per_10k',              'Врачей на 10 тыс.'),
80          ('hospital_beds_per_10k',        'Коек на 10 тыс.'),
81          # Economic
82          ('grp_per_capita',               'ВРП на душу, руб.'),
83          ('investment_per_capita',        'Инвестиции на душу, руб.'),
84          ('average_monthly_wage',         'Среднемесячная зарплата, руб.'),
85          ('retail_trade_per_capita',      'Оборот розницы на душу, руб.'),
86          # Environmental
87          ('emissions_thousand_tons',      'Выбросы в атмосферу, тыс. т'),
88          ('captured_pollutants_pct',      'Доля уловленных веществ, %'),
89          ('fresh_water_use',              'Забор свежей воды, млн м³'),
90          ('polluted_wastewater',          'Сброс стоков, млн м³'),
91          ('environmental_spending_per_capita', 'Расходы на охрану среды на душу, руб.'),
92      ]
93
94      our_metrics = [
95          ('Социальные_pct',       'Доля социальной категории, %'),
96          ('Экономические_pct',    'Доля экономической категории, %'),
97          ('Экологические_pct',    'Доля экологической категории, %'),
98          ('pos_economic',         'Позитивность экономической, %'),
99          ('pos_social',           'Позитивность социальной, %'),
100         ('pos_environmental',    'Позитивность экологической, %'),
101     ]
102
103     corr_results = []
104     for metric, metric_name in our_metrics:
105         for ind, ind_name in rostat_indicators:
106             subset = merged[[metric, ind]].dropna()
107             if len(subset) < 3:
108                 continue
109             tau, pval = kendalltau(subset[metric], subset[ind])
110             corr_results.append({
111                 'Характеристика повестки': metric_name,
```

```
            'Показатель Росстата': ind_name,
            'kendall_tau': round(tau, 3),
            'p_value': round(pval, 4),
            'n': len(subset),
        })

corr_df = pd.DataFrame(corr_results)
corr_df = corr_df.sort_values('kendall_tau', key=abs, ascending=False)
corr_path = os.path.join(OUTPUT_DIR, 'correlations.csv')
corr_df.to_csv(corr_path, index=False, float_format='%.3f')
print(f'\nКорреляции Кендалла сохранены: {corr_path}')
top = corr_df[abs(corr_df['kendall_tau']) > 0.3]
print(top.to_string(index=False))

# === Panel FE regression ===
reg_pairs = [
    ('pos_economic',      'grp_per_capita'),
    ('pos_economic',      'investment_per_capita'),
    ('pos_social',        'unemployment_pct'),
    ('pos_social',        'grp_per_capita'),
    ('pos_environmental', 'emissions_thousand_tons'),
    ('Экологические_pct',  'grp_per_capita'),
    ('Социальные_pct',    'unemployment_pct'),
    ('Экономические_pct', 'investment_per_capita'),
]

print('\n=== Панельная регрессия (FE по регионам, n=12) ===')
reg_results = []
for y_col, x_col in reg_pairs:
    res = panel_fe_regression(merged, y_col, x_col)
    if res:
        coef, pval, r2, n = res
        reg_results.append({
            'Зависимая': y_col,
            'Независимая': x_col,
            'Коэфф': round(coef, 4),
            'p-value': round(pval, 4),
            'R²': round(r2, 3),
            'n': n,
        })
        sig = '**' if pval < 0.05 else ('*' if pval < 0.1 else '')
        print(f'  {y_col} ~ {x_col}: beta={coef:.4f} (p={pval:.4f}){sig} R2={r2:.3f} n={n}')

reg_df = pd.DataFrame(reg_results)
reg_path = os.path.join(OUTPUT_DIR, 'panel_regressions.csv')
reg_df.to_csv(reg_path, index=False, float_format='%.4f')
print(f'\nРегрессии сохранены: {reg_path}')

# === Scatter plots (key pairs) ===
pairs = [
    ('grp_per_capita', 'pos_economic', 'ВРП на душу vs экономическая позитивность'),
    ('unemployment_pct', 'pos_social', 'Безработица vs социальная позитивность'),
    ('emissions_thousand_tons', 'pos_environmental', 'Выбросы vs экологическая позитивность'),
    ('grp_per_capita', 'Экологические_pct', 'ВРП на душу vs доля экол. категории'),
    ('investment_per_capita', 'pos_economic', 'Инвестиции на душу vs экон. позитивность'),
]

colors = {'Астраханская область': '#FF9800', 'Омская область': '#2196F3', 'Татарстан': '#4CAF50'}
for x_col, y_col, title in pairs:
    subset = merged[[x_col, y_col, 'region', 'year']].dropna()
    if len(subset) < 3:
```

```
            continue
        fig, ax = plt.subplots(figsize=(8, 6))
        for reg in subset['region'].unique():
            rdf = subset[subset['region'] == reg]
            ax.scatter(rdf[x_col], rdf[y_col], c=colors.get(reg, '#999'),
                       label=reg, s=80, edgecolors='black', linewidth=0.5)
            for _, row in rdf.iterrows():
                ax.annotate(str(int(row['year'])), (row[x_col], row[y_col]),
                            textcoords='offset points', xytext=(5, 5), fontsize=8)

        if len(subset) >= 3:
            tau, _ = kendalltau(subset[x_col], subset[y_col])
            ax.set_title(f'{title}\nKendall tau = {tau:.2f}')
        ax.set_xlabel(x_col.replace('_', ' ').title())
        ax.set_ylabel(y_col.replace('_', ' ').title())
        ax.legend()
        ax.grid(True, alpha=0.3)
        plt.tight_layout()
        safe_name = title.replace(' ', '_').replace('/', '_')
        plt.savefig(os.path.join(OUTPUT_DIR, f'{safe_name}.png'), dpi=150)
        plt.close()
        print(f'  График: {safe_name}.png')

    print(f'\nГотово. Результаты в: {OUTPUT_DIR}/')

if __name__ == '__main__':
    main()
```